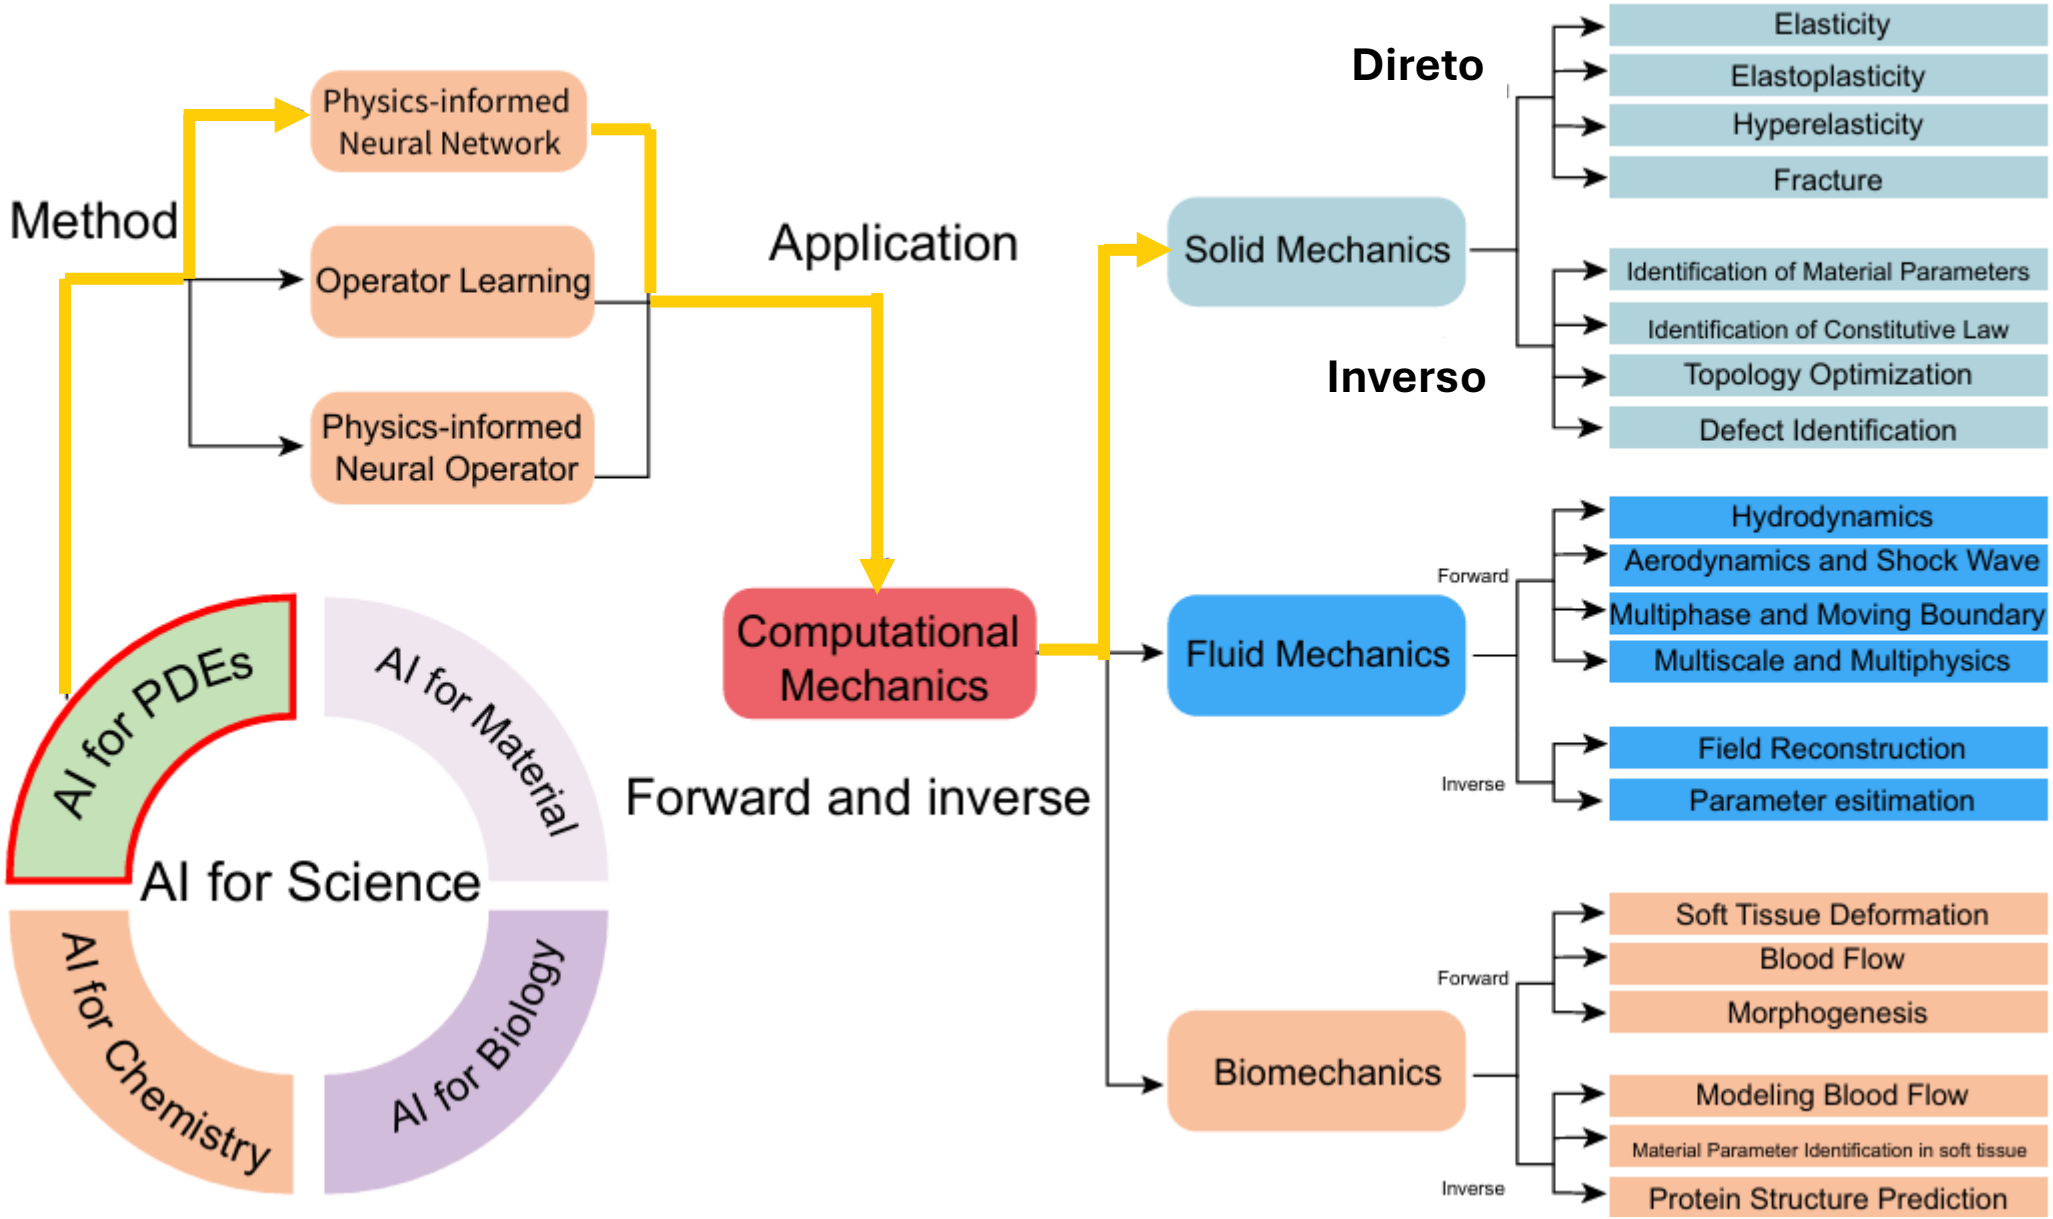
Redes Neurais Informadas por Física em Mecânica Computacional

Tópicos Especiais em Mecânica dos Sólidos

Eng. Paulo de Souza Silva e Prof. Dr. Wallace Gusmão

Junho de 2025





Wang etal (2024a)



Revisão Inicial

Equações Diferenciais
Notação Indicial
Engenharia de Estruturas
Redes Neurais

Uma breve ideia das EDOs e EDPs

Equações Diferenciais Ordinárias (EDOs) e Parciais (EDPs)

EDOs: envolvem derivadas em relação a uma única variável independente. $\frac{dy}{dx} = f(x, y)$

EDPs: envolvem derivadas parciais com relação a duas ou mais variáveis independentes. $\frac{\partial u}{\partial t} = k\frac{\partial^2 u}{\partial x^2}$

Classificação

Linear: a função incógnita e suas derivadas aparecem apenas na primeira potência e não multiplicadas entre si. Ex.: $y'' + p(x)y' + q(x)y = g(x)$

Não-linear: contém termos com potências, produtos ou funções não-lineares da incógnita ou de suas derivadas.

Homogênea: se o termo independente for zero. Ex.: $y''+p(x)y'+q(x)y=0$

Não-homogênea: possui um termo independente não nulo. Ex.: $y'' + p(x)y' + q(x)y = g(x)$, com $g(x) \neq 0$

Uma breve ideia das EDOs e EDPs

Problema de Valor Inicial

Problema onde se busca uma solução para uma EDO ou EDP com condições especificadas em um ponto ou superfície inicial.

Exemplo: $\frac{dy}{dx} = f(x, y)$ com $y(x_0) = y_0$

Condições de Contorno: Neumann e Dirichlet

Dirichlet: especifica o valor da **função** na fronteira do domínio. Ex.: $u = g$ em $\partial\Omega$.

Neumann: especifica o valor da **derivada normal** da função na fronteira (fluxo). Ex.: $\frac{\partial u}{\partial n} = h$ em $\partial\Omega$, onde $\frac{\partial}{\partial n}$ indica a derivada na direção normal à fronteira.

Uma breve ideia das EDOs e EDPs

Operador Nabla: ∇

- **Operação Gradiente**: Aplicado a função escalar – (Leva de escalar para vetor)

$$\nabla f(x,y,z) = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}\right)$$

- **Operação Divergente**: Aplicado a um campo vetorial $F = (F_x, F_y, F_z)$ – (Leva de vetor para escalar)

$$\nabla \cdot F = \frac{\partial F_x}{\partial x} + \frac{\partial F_y}{\partial y} + \frac{\partial F_z}{\partial z}$$

- **Operação Rotacional**: Aplicado a um campo vetorial – (Mantém-se vetor)

$$\nabla \times F = \left(\frac{\partial F_z}{\partial y} - \frac{\partial F_y}{\partial z}, \frac{\partial F_x}{\partial z} - \frac{\partial F_z}{\partial x}, \frac{\partial F_y}{\partial x} - \frac{\partial F_x}{\partial y}\right)$$

Notação Indicial ⚠

Em mecânica é comum usar notação indicial para expressar de forma compacta vetores, matrizes e sistemas de equações.

Nesse sentido entra o conceito de tensores de primeira e segunda ordem e algumas operações como contração simples e dupla, para mais detalhes consultar: Elementos de Álgebra e Analise Tensorial para Mecânica

Tensor de Ordem 1: $f_i = [f_1, f_2]^T$ para definir um vetor

Tensor de Ordem 2: $\sigma_{ij} = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}$ para definir uma matriz (ex. ao lado é uma matriz 2D).

$\sigma_{ij,j} = \nabla \cdot \sigma = \begin{bmatrix} \frac{\partial \sigma_{11}}{\partial x_1} + \frac{\partial \sigma_{12}}{\partial x_2} \\ \frac{\partial \sigma_{21}}{\partial x_1} + \frac{\partial \sigma_{22}}{\partial x_2} \end{bmatrix}$ é o divergente do tensor (derivada simbolizada por uma **vírgula**)

δ_{ij} é delta de Kronecker se $i = j$ então $\delta_{ii} = \delta_{jj} = 1$ e vale zero caso contrário.

Mecânica das Estruturas

Conceitos Essenciais

Dentro dos problemas que são abordados alguns conceitos são essenciais:

- Força, tensões, deformação, deslocamentos, deflexão, momento fletor;
- Parâmetros de Lamé, Módulo de Elasticidade, coeficiente de Poisson;
- Barra, viga, placas;

Disciplinas/Temas

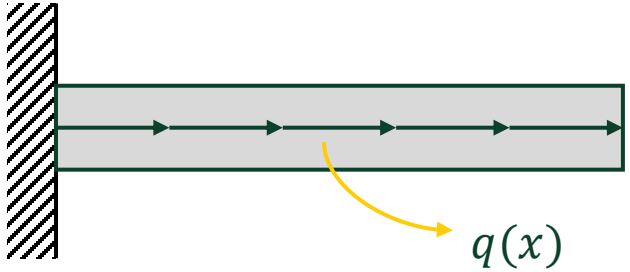
Algumas disciplinas ou temas que podem ser estudados antes de se aplicar as redes neurais:

- Mecânica dos Sólidos
- Teoria da Elasticidade
- Mecânica do Contínuo
- Placas e Cascas
- Vibrações
- Método dos Elementos Finitos

Mecânica das Estruturas

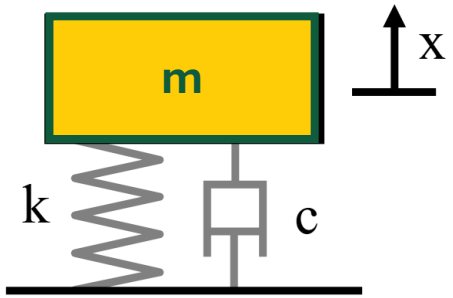
Barra Simples

$$\frac{d}{dx}\left(EA\frac{du}{dx}\right) = -q(x)$$



Massa-Mola-Amortecedor

$$M\ddot{u} + C\dot{u} + Ku = F$$

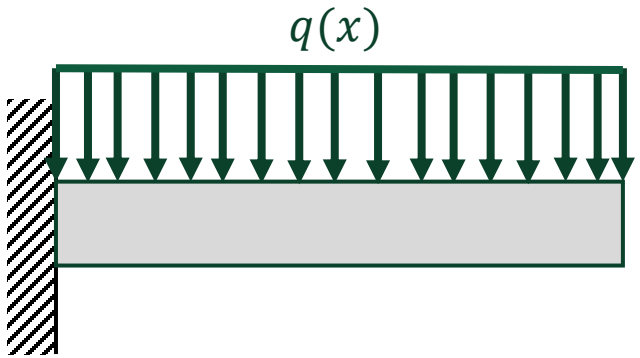


Viga de Euler-Bernoulli

$$EI\frac{d^4y}{dx^4} = -q(x)$$

$$EI\frac{d^3y}{dx^3} = V(x)$$

$$EI\frac{d^2y}{dx^2} = M(x)$$

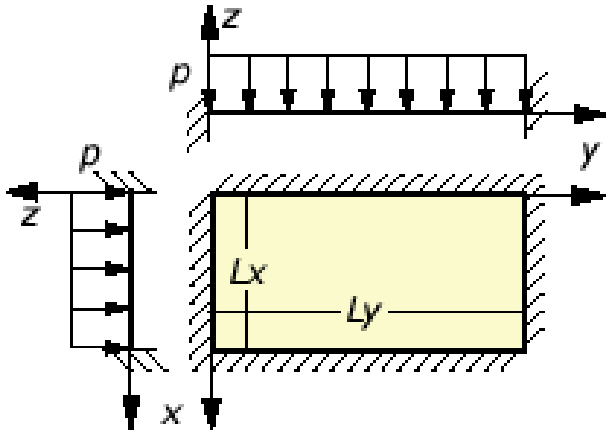


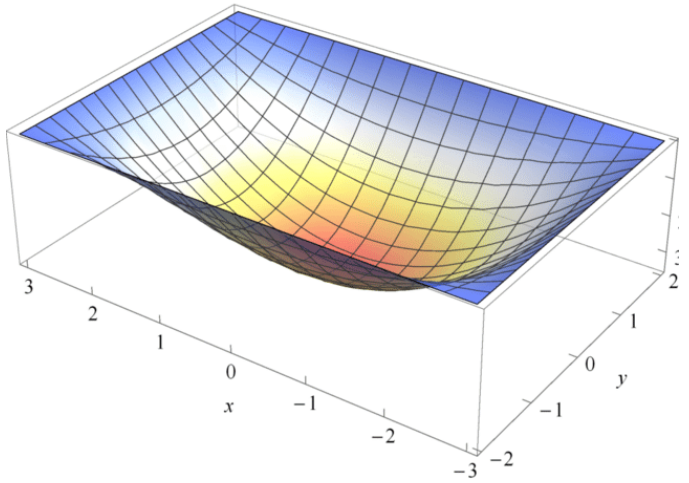
Mecânica das Estruturas

Deflexão em Placas

$$\frac{\partial^4 w}{dx^4} + 2\frac{\partial^4 w}{\partial^2 x\,\partial^2 y} + \frac{\partial^4 w}{\partial^4 y} = \frac{p}{D} \quad \text{ou} \quad \nabla^4 w = \frac{p}{D}$$

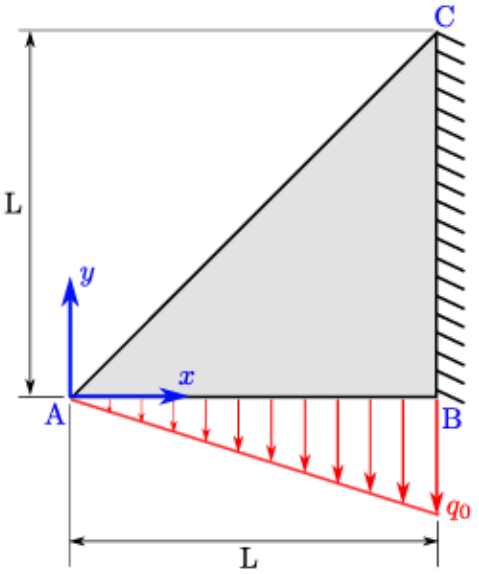
$$D = \frac{Et^3}{12(1-\nu^2)}$$

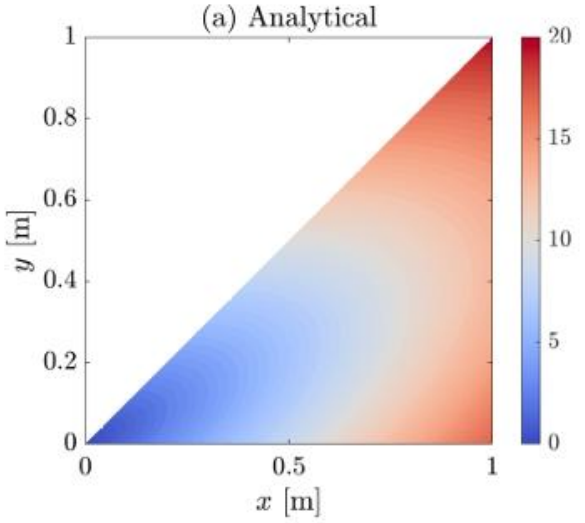




Tensões em Placas (Função de Airy)

$$\frac{\partial^4 \phi}{dx^4} + 2\frac{\partial^4 \phi}{\partial^2 x\,\partial^2 y} + \frac{\partial^4 \phi}{\partial^4 y} = 0$$





Mecânica das Estruturas

Elasticidade Linear

$$\nabla\boldsymbol{\sigma} + \boldsymbol{f} = \mathbf{0}$$

$$\boldsymbol{\sigma} = \lambda\delta_{ij}\boldsymbol{\varepsilon} + 2\mu\boldsymbol{\varepsilon}$$

$$\boldsymbol{\varepsilon} = \frac{\mathbf{1}}{\mathbf{2}}[\nabla\mathbf{u} + (\nabla\mathbf{u})^{\mathbf{T}}]$$

Parâmetros de Lamé:

$$\lambda = \frac{E\nu}{(1+\nu)(1-2\nu)}$$

$$\mu = \frac{E}{2(1+\nu)}$$

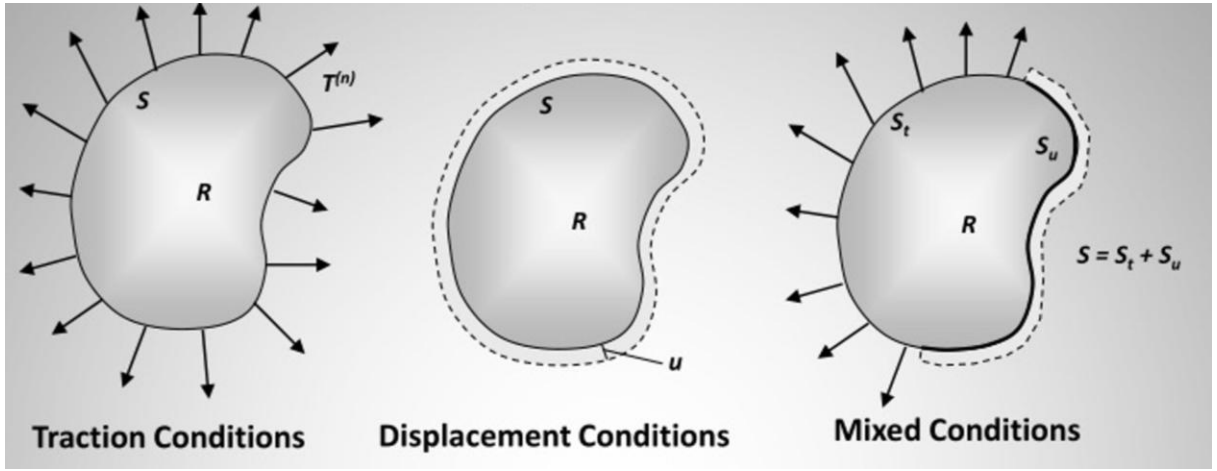
Condições Iniciais e de Contorno

Deslocamentos IC: $u(x,0) = u_0(x)$ $em\ \Omega$

Velocidades IC: $\dot{u}(x,0) = v_0(x)$ $em\ \Omega$

Deslocamentos BC: $u = \bar{u}$ $em\ \Gamma$

Forças BC: $t = \bar{t} = \boldsymbol{\sigma}n$ $em\ \Gamma$





Aplicações em Mecânica Computacional

Frentes da Mecânica dos Sólidos

Problemas Diretos e Inversos

Frentes de Mecânica dos Sólidos

Grandes Áreas

Mecânica da Elasticidade Linear

Mecânica da Elasto-plasticidade

Mecânica da Hiper elasticidade

Modelagem Viscoelástica

Fratura Mecânica

Foco de Determinação

Deformações

Tensões

Deslocamentos

Propriedades

Temas

Barras

Vigas

Euler-Bernoulli

Timoshenko

Viga em Fundação Elástica

Placas

Placas de Kirchoff-Love

Funções de Airy

Placa em Fundação Elástica

Materiais elastoplasticos e hiperelasticos

Otimização Topológica

Problemas Dinâmicos

Vibrações

Terremotos (prédios)

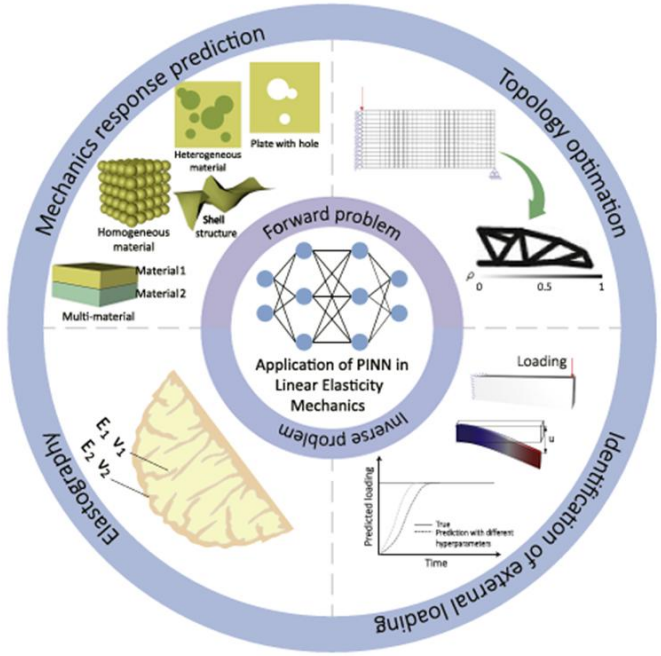
Transição de Campo de Fase

Identificações

Módulo de Elasticidade e Coeficiente de Poisson

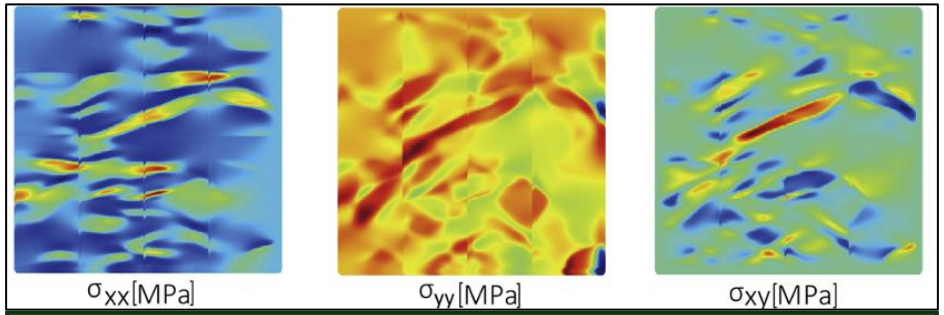
Equações Constitutivas

Identificação de Defeitos

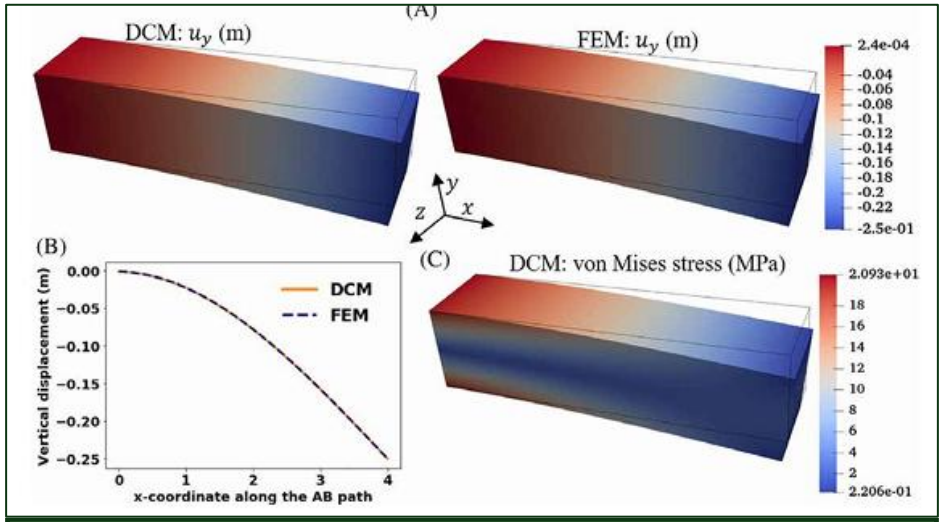


Hu etal (2024)

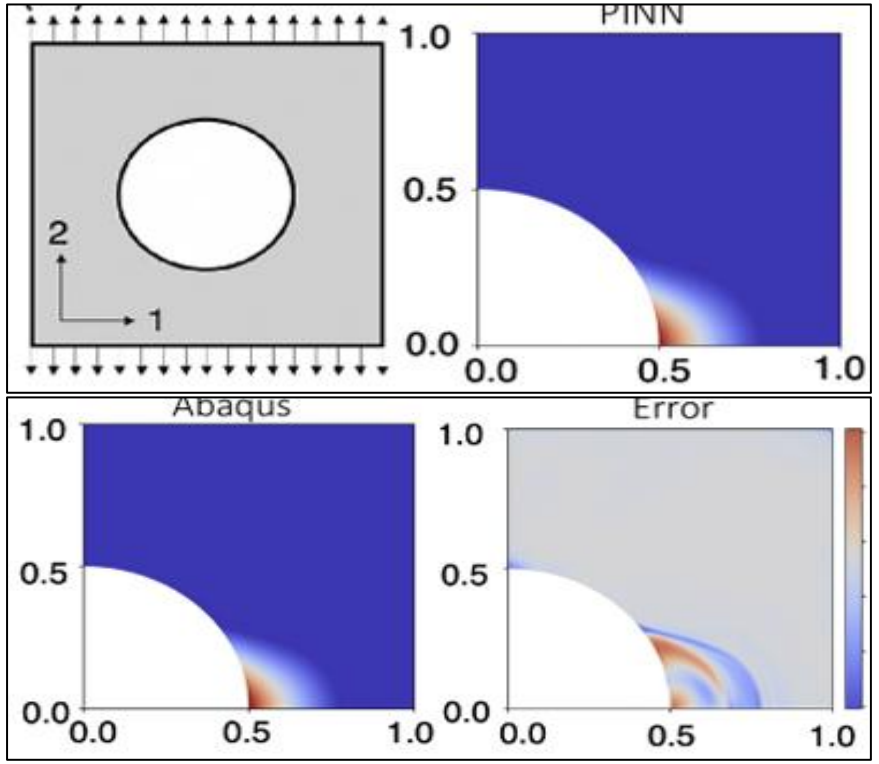
Problemas Diretos



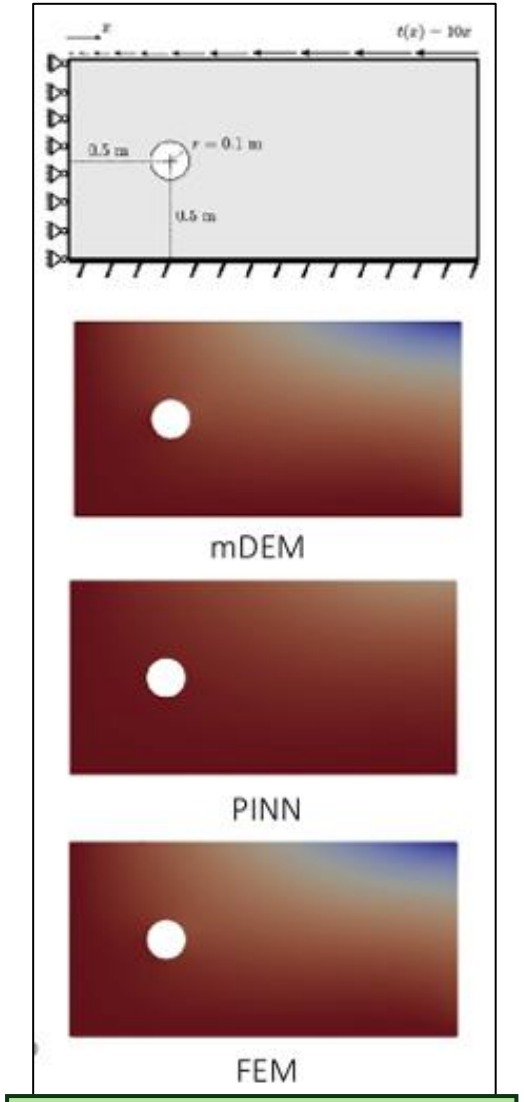
Tensões em um Material Elástico



Deslocamentos em Elastoplásticos

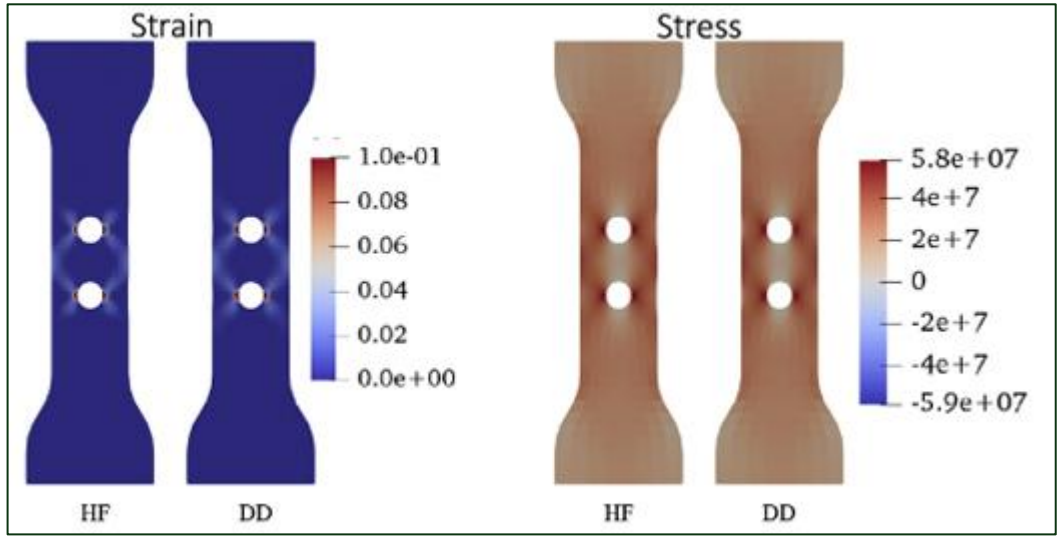


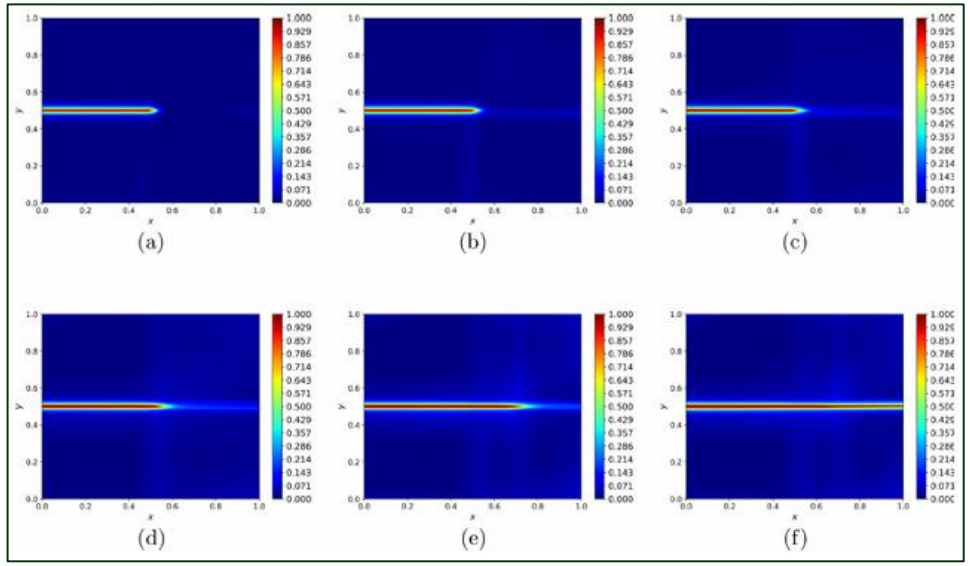
Tensões em um Material Plástico

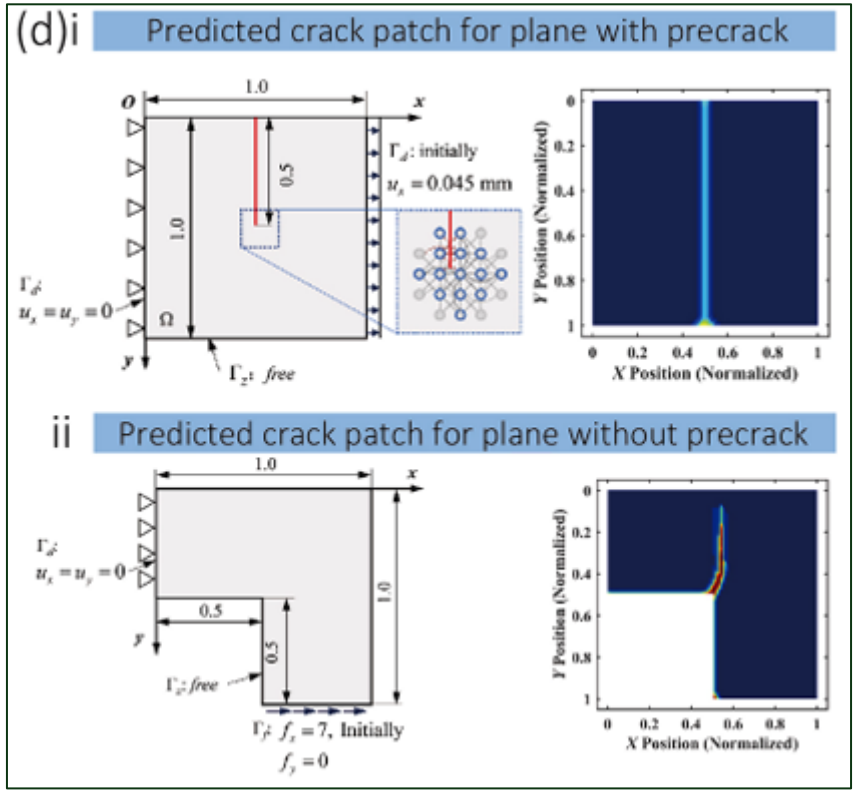


Tensões em um Material Hiperelástico

Problemas Diretos

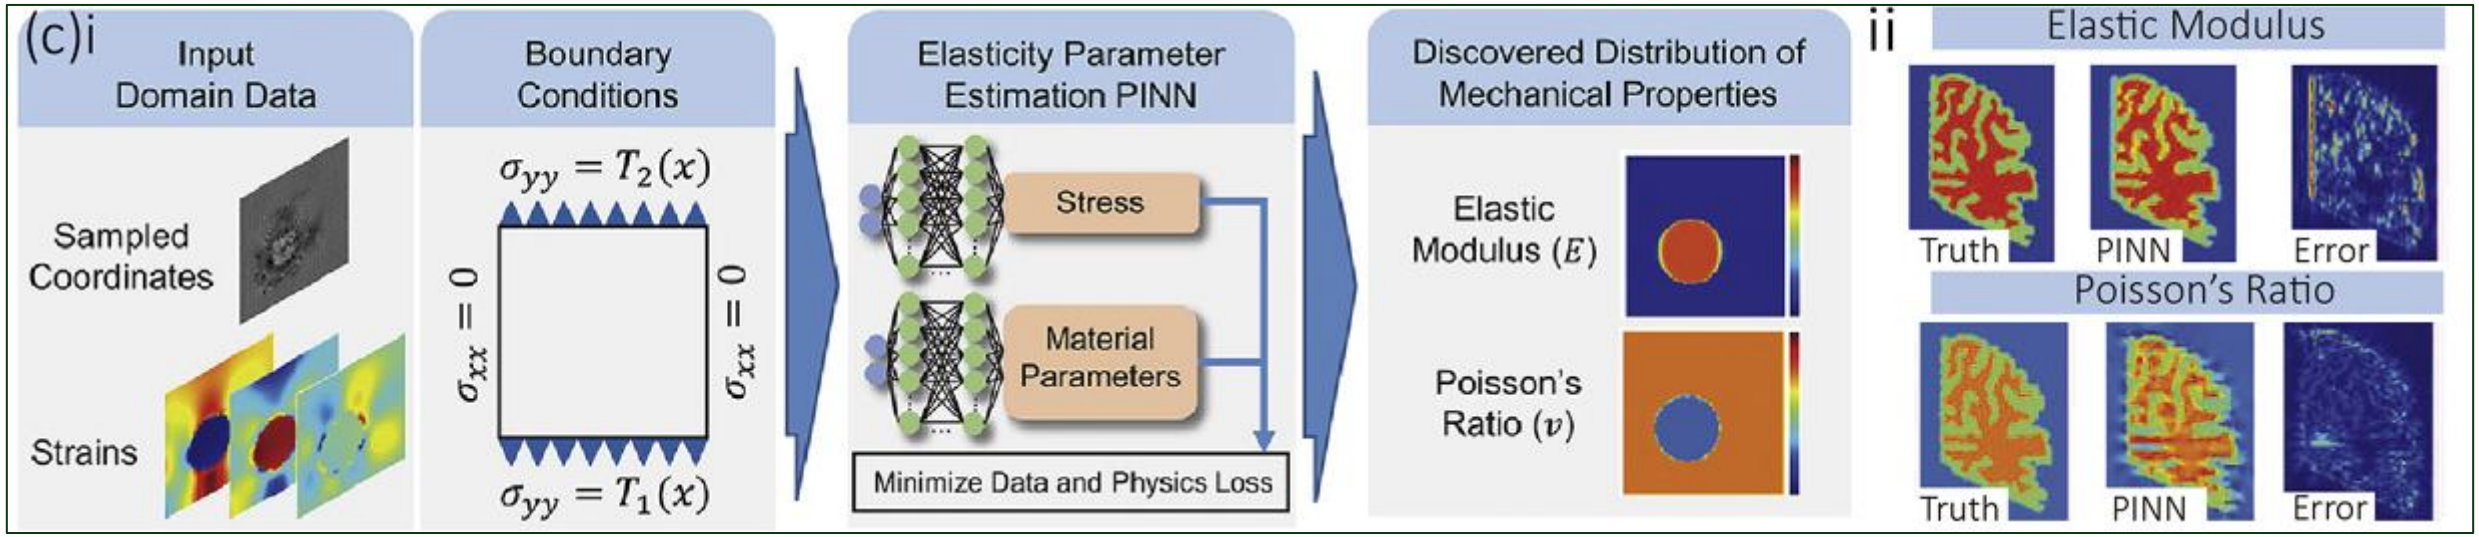


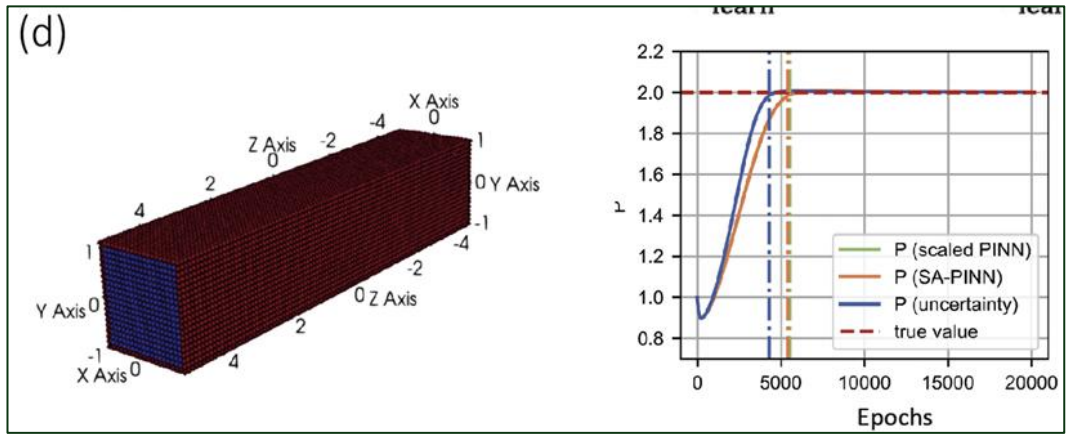




Propagação de Trincas e Fratura Mecânica

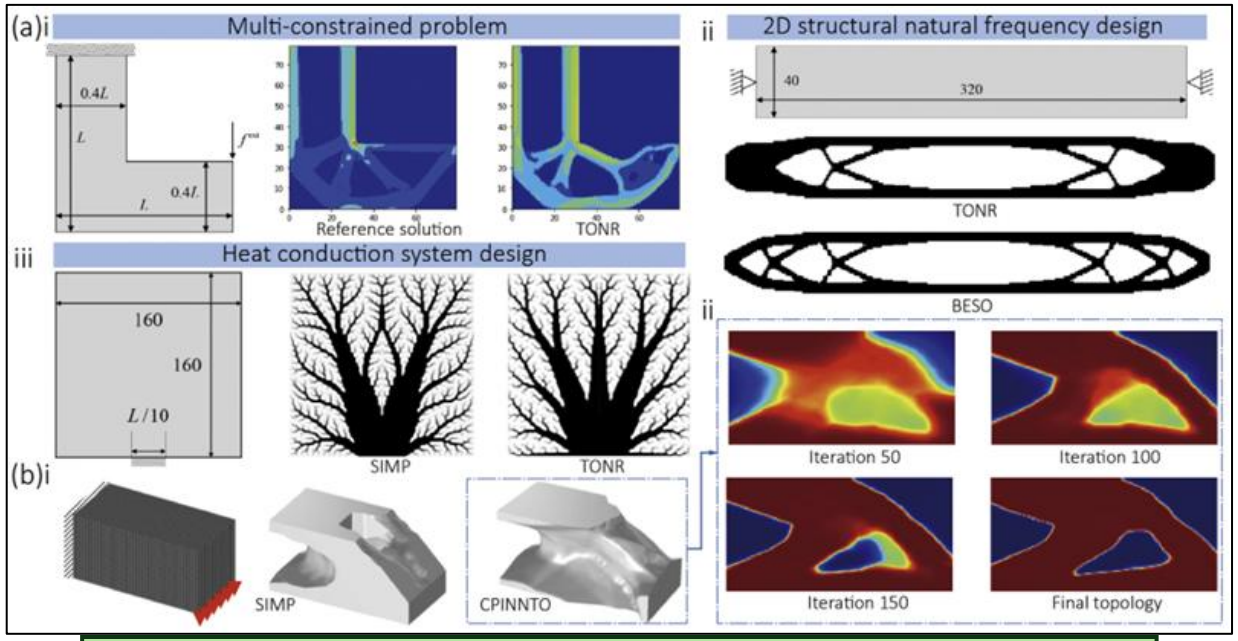
Problemas Inversos



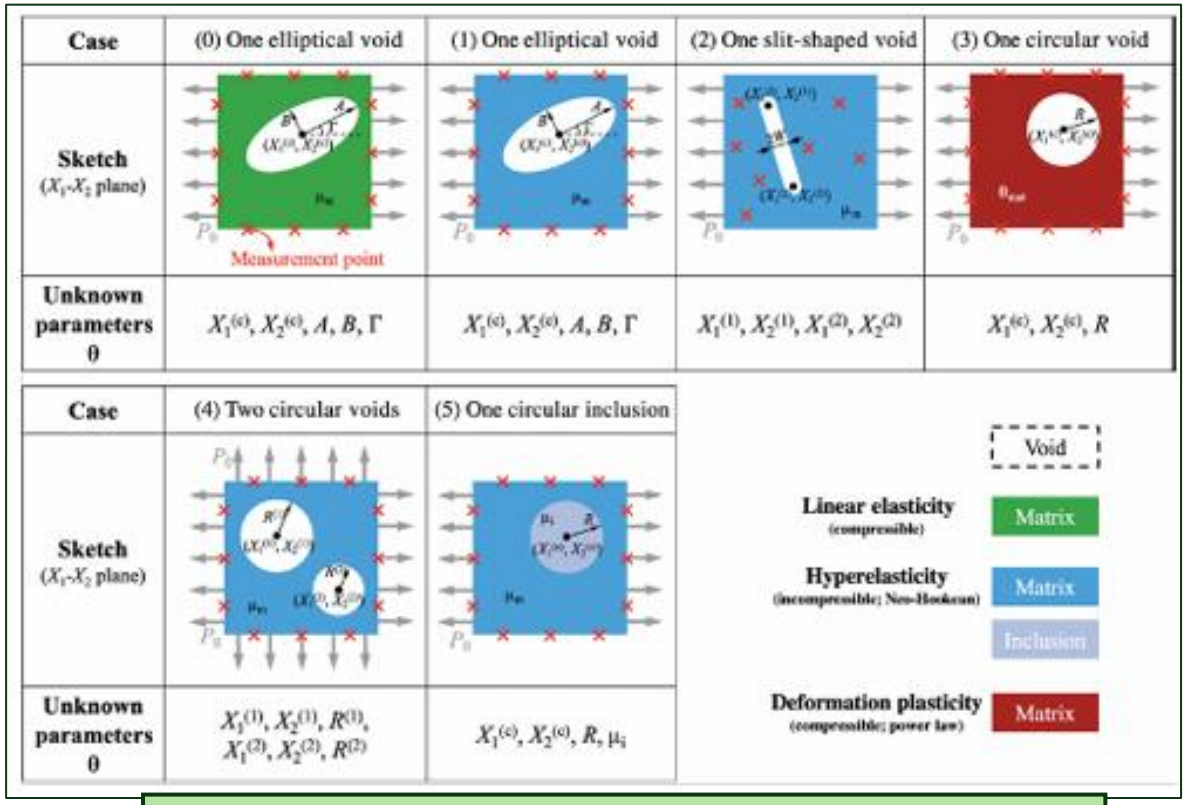


Identificação de Parâmetros

Problemas Inversos

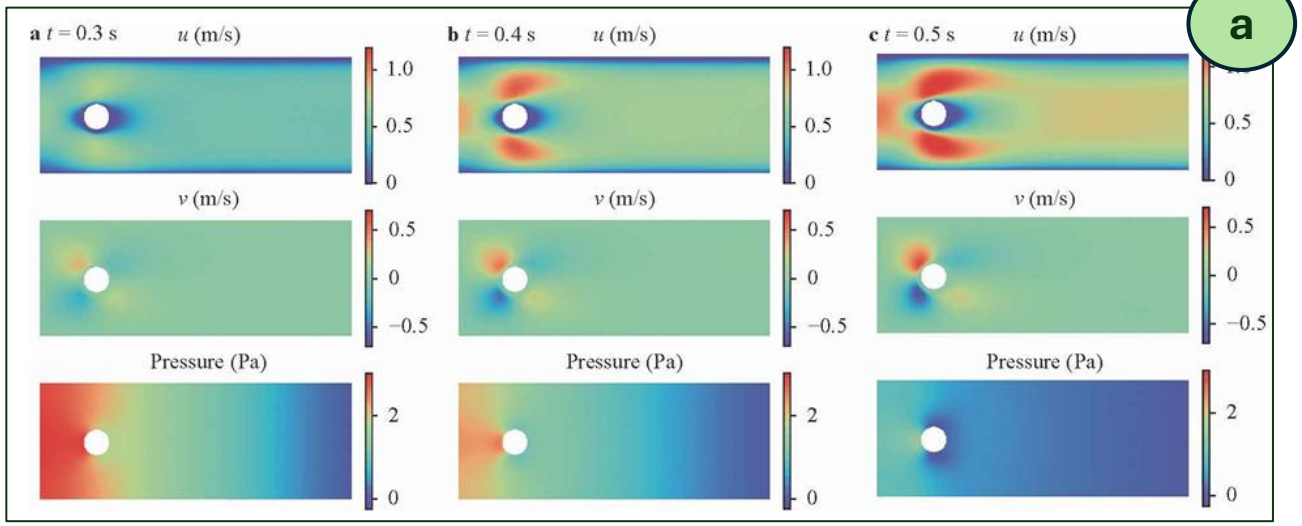


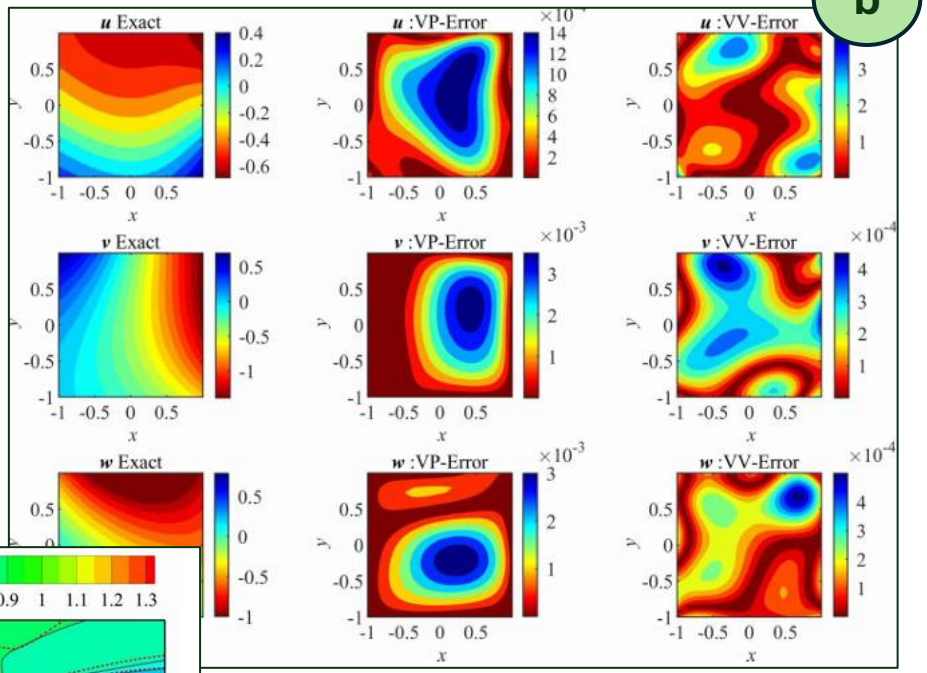
Otimização Topológica

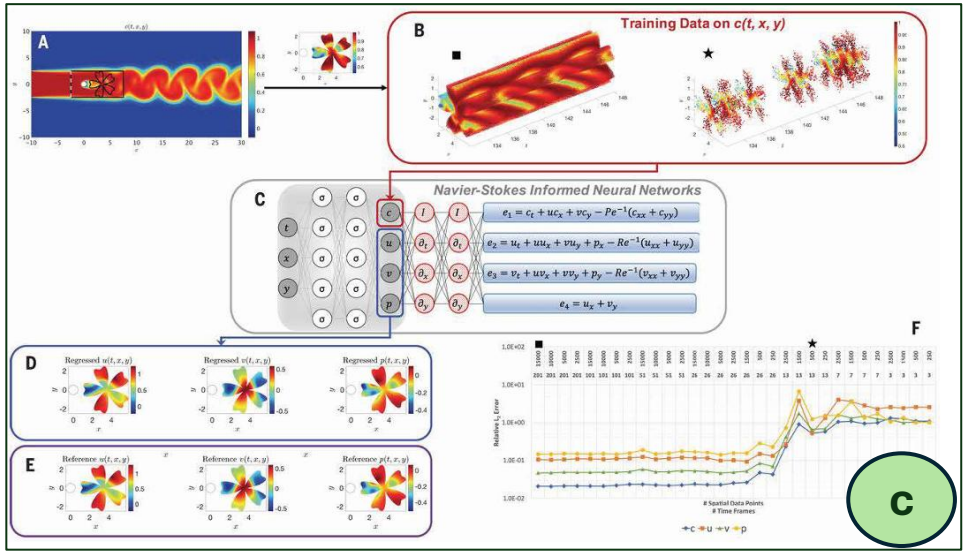


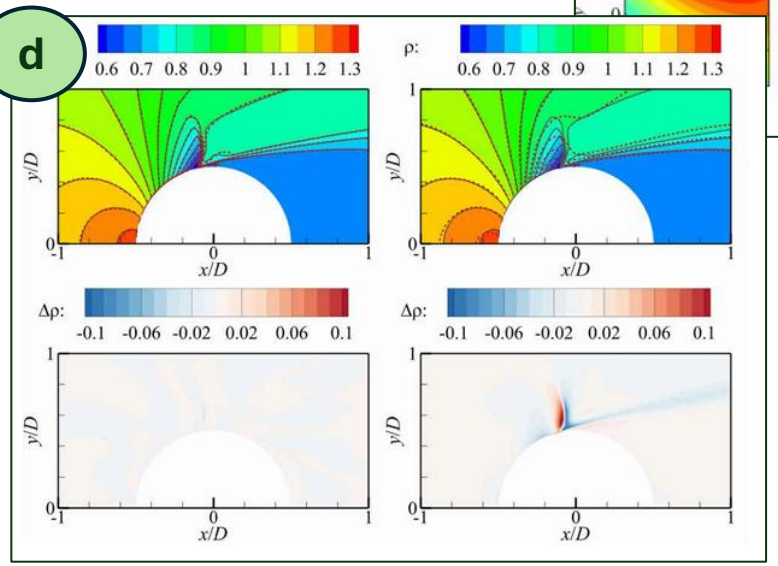
Identificação de Defeitos

Problemas em Mecânica dos Fluídos









a) Fluído incompressível laminar
b) Eq. Navier-Stokes
c) Reconstrução de Campos
d) Resolução de RANS



Vídeos e Referências

Vídeos Recomendados

Vídeos

Physics Informed Neural Networks (PINNs): "PyTorch" Solve Physical Systems with Deep Neural Networks: https://youtu.be/MtHvs5FvtME?si=MeGVe9HF8pCkKN2j <Acesso em: 13/05/2025>

Physics Informed Neural Networks for Fluid Mechanics: https://youtu.be/EHrgSPHZG3Y?si=JUOWe1pC_7bt6i18 <Acesso em: 13/05/2025>

Playlists

Neural Networks / Deep Learning: https://youtube.com/playlist?list=PLblh5JKOoLUIxGDQs4LFFD--41Vzf-ME1 <Acesso em: 03/06/2025>

Physics Informed Machine Learning: https://youtube.com/playlist?list=PLMrJAkhIeNNQ0BaKuBKY43k4xMo6NSbBa <Acesso em: 06/06/2025>

Physics Informed Neural Networks (PINNs): https://youtube.com/playlist?list=PLM7DTyYjZGuLmg3f6j40fEF18jyQmYsC2 <Acesso em: 06/06/2025>

Referências

Dwivedi (2019) Physics Informed Extreme Learning Machine (PIELM)–A rapid method for the numerical solution of partial differential equations

Estevão etal (2023) Physics-informed Neural Networks For Solving Elasticity Problems

Gao etal (2020): PhyGeoNet: Physics-Informed Geometry-Adaptive Convolutional Neural Networks for Solving Parameterized Steady-State PDEs on Irregular Domain

Gao etal (2022): Physics-informed graph neural Galerkin networks: A unified framework for solving PDE-governed forward and inverse problems

Haghighat etal (2020): A physics-informed deep learning framework for inversion and surrogate modeling in solid mechanics

Hu etal (2024): Physics-informed Neural Networks (PINN) for computational solid mechanics: Numerical frameworks and applications

Jagtap (2020): Conservative physics-informed neural networks on discrete domains for conservation laws: Applications to forward and inverse problems

Referências

Jagtap (2021): Extended physics-informed neural networks (XPINNs): A generalized space-time domain decomposition based deep learning framework for nonlinear partial differential equations

Kharazmi (2019) VPINNs: Variational Physics-informed Neural Networks For Solving Partial Differential Equations

Kharazmi (2020) hp-VPINNs: Variational Physics-Informed Neural Networks With Domain Decomposition

Kollmannsberger etal (2021): Deep Learning in Computational Mechanics - An Introductory Course

Liu etal (2025) – KAN: Kolmogorov – Arnold Networks

Nentidis (2022) - Evaluation of Physics Informed Neural Networks in engineering simple structural analysis problems

Nguyen-Than (2019) - A deep energy method for finite deformation hyperelasticity

Referências

Raissi (2017) - Physics Informed Deep Learning (Part I): Data-driven Solutions of Nonlinear Partial Di erential Equations

Ramabathiran (2021)- SPINN: Sparse, Physics-based, and partially Interpretable Neural Networks for PDEs

Samaniego (2019) - An Energy Approach to the Solution of Partial Differential Equations in Computational Mechanics via Machine Learning: Concepts, Implementation and Applications

Vu-Quoc & Humer (2023): Deep Learning Applied to Computational Mechanics: A comprehensive Review, State of the Art, and the Classics

Wang etal (2024a)- Artificial intelligence for partial differential equations in computational mechanics: A review

Wang etal (2024b)- Kolmogorov-Arnold-Informed neural network: A physics-informed deep learning framework for solving forward and inverse problems based on Kolmogorov–Arnold Networks



Obrigado!