Redes Neurais Informadas por Física

Tópicos Especiais em Transferência de Calor

MSc. Eng. Paulo de Souza Silva e Prof. Dr. Daniel Dezan

Novembro de 2026





Variações da PINN

As 10 variações da PINN ”Forte”

Tipos de PINNs “Forte”

Métodos	Tipo de Rede	Função de Teste
PIELM	Extreme Learning Machine	Delta de Dirac
VPINNs	Fully Connected	Funções de Peso Mistas
cPINN	Fully Connected	Delta de Dirac
hp-VPINNs	Fully Connected	Polinômios Ortogonais
PhyGeoNet	Convolutional Network (CNN)	Delta de Dirac
XPINN	Fully Connected	Delta de Dirac
PIGCN	Graph Convolution (GCN)	Espaço de Funções Tentativa
SPINN	Radial Basis Function	Espaço de Funções Tentativa
BINN	Fully Connected	Soluções Fundamentais de EDPs
KINN	Kolmogorov Arnold Network	Delta de Dirac

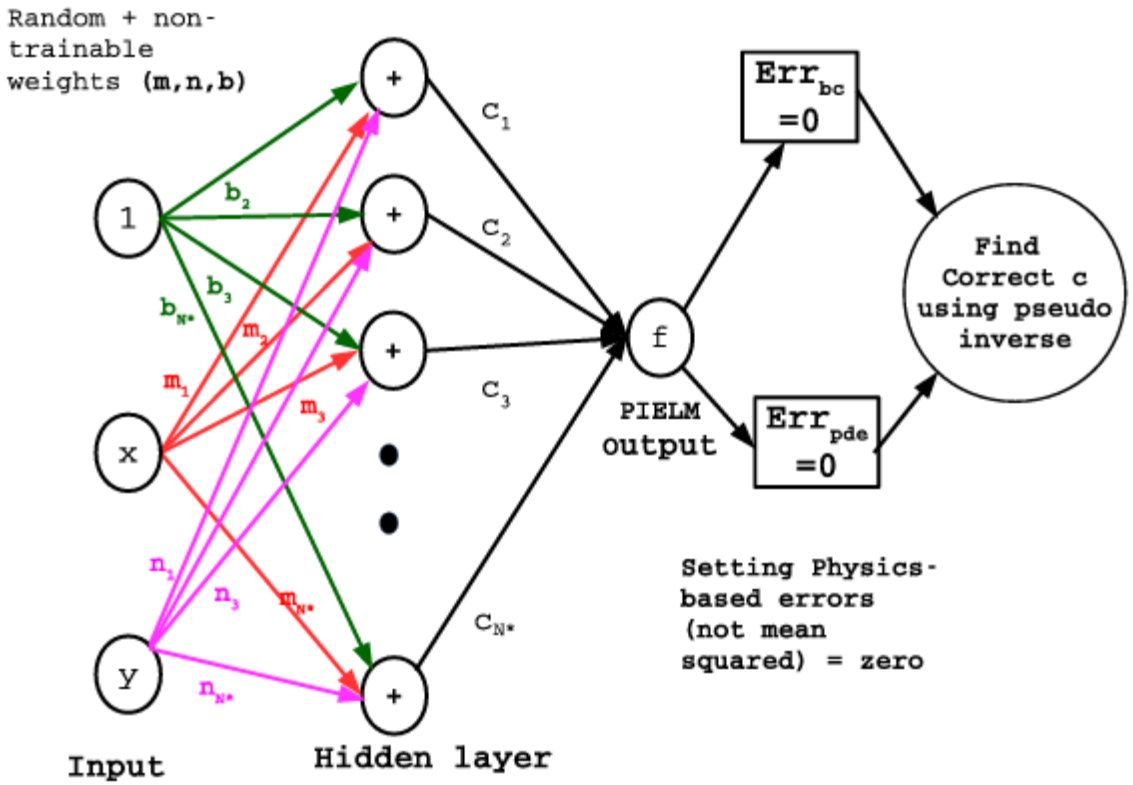
Adaptado de Wang etal (2024a)

PIELM: PI Extreme Learning Machine

Esta abordagem combina os princípios do PINN com a arquitetura e o algoritmo de treinamento das Extreme Learning Machines (ELM).

No PIELM, os pesos e vieses da **camada de entrada** da rede neural são **atribuídos aleatoriamente** e **permanecem fixos**, enquanto os pesos da **camada de saída** são calculados **analiticamente** minimizando a função de perda física.

Isso torna o treinamento significativamente **mais rápido** do que em PINNs tradicionais que usam otimização iterativa para todos os parâmetros.



Dwivedi (2019)

Obs: **Pseudo-Inversa de Penrose (pinv)**

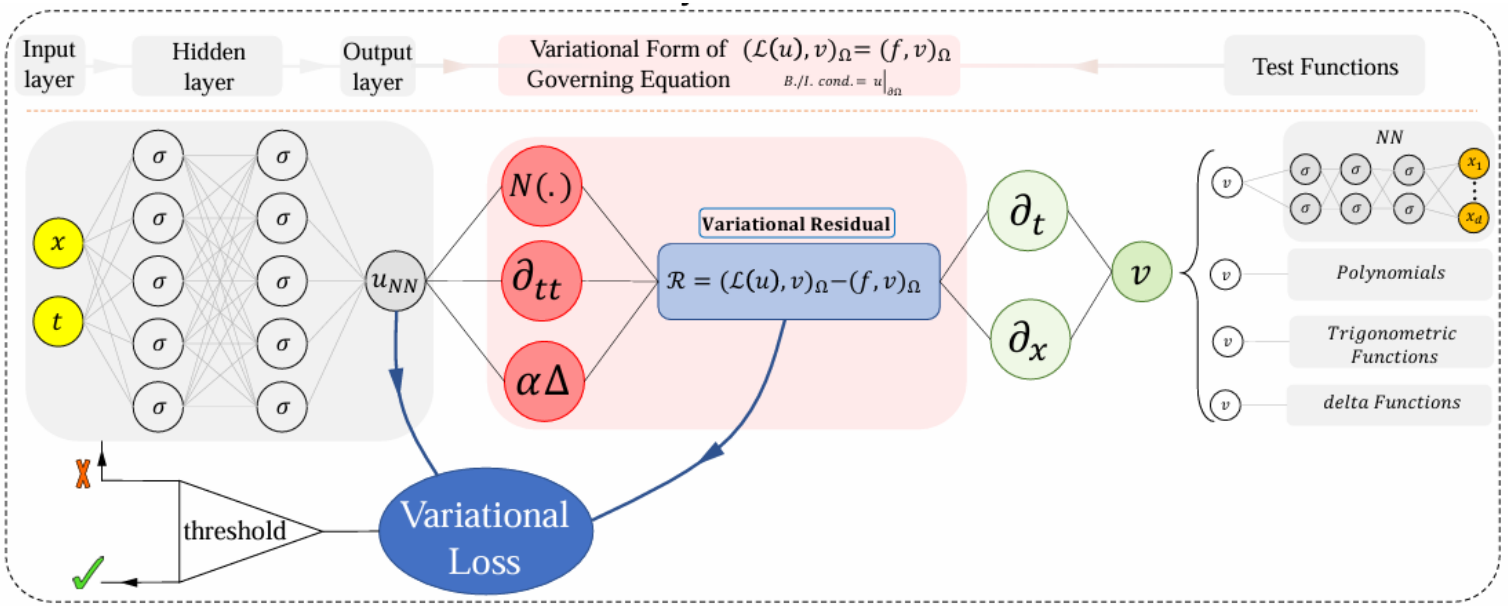
$$\boldsymbol{H}(\boldsymbol{x},\boldsymbol{y})\vec{c} = \vec{f}$$

$$\vec{c} = pinv(\boldsymbol{H})\vec{f}$$

VPINN: Variational PINN

Ao contrário do PINN tradicional que se baseia na forma **forte (colocação) da EDP**, o VPINN incorpora a **formulação variacional (forma fraca) da EDP** na função de perda.

Isso geralmente envolve a **integração dos resíduos** da EDP ponderados por funções de teste, o que pode reduzir a ordem dos operadores diferenciais necessários e, em alguns casos (para redes rasas), permitir o cálculo analítico dessas integrais.



$$(\mathcal{L}^q u_{NN}(\mathbf{x}), v(\mathbf{x}))_\Omega = (f(\mathbf{x}), v(\mathbf{x}))_\Omega$$
$$u(\mathbf{x}) = h(\mathbf{x}), \quad \mathbf{x} \in \partial\Omega$$

$$Residual^v = \mathcal{R} - F - r^b,$$
$$\mathcal{R} = (\mathcal{L}^q u_{NN}, v)_\Omega, \quad F = (f,v)_\Omega,$$

Espaço de Tentativa: Redes Neurais
Espaço de Teste: Polinômios de Legendre
$(\cdot\,,\cdot)$ Produto interno

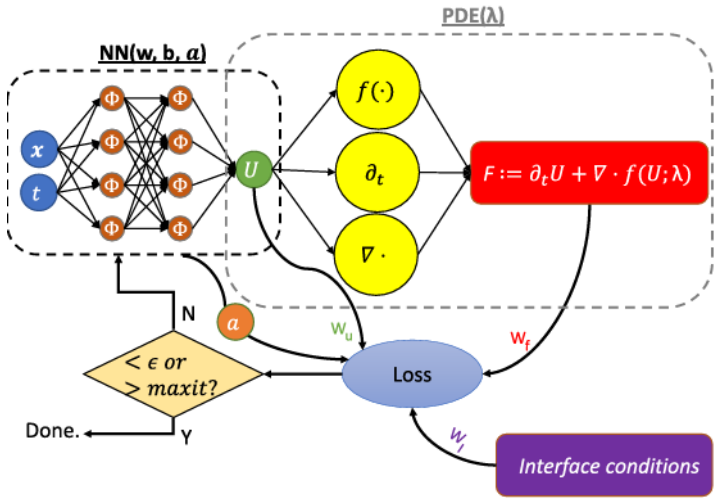
Kharazmi (2019)

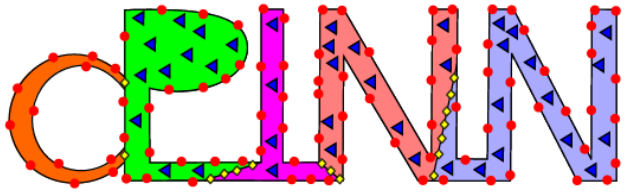
cPINN: Conservative PINN

O cPINN introduz a ideia de **decomposição de domínio** para resolver EDPs, utilizando leis de conservação.

Ele divide o domínio computacional em vários subdomínios, **cada um com sua própria rede neural.**

Impõe **condições de continuidade** (incluindo continuidade de fluxo conservativo) nas interfaces entre os subdomínios para **"costurar"** a **solução global**, permitindo maior flexibilidade na arquitetura local e paralelização.





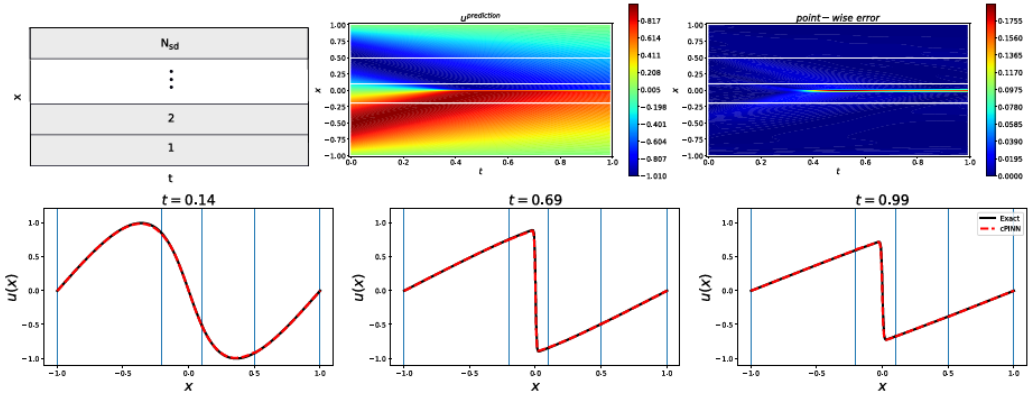


Fig. 4. N_{sd} sub-domain numbering, cPINN solution and point-wise error (top row, left to right), and comparison of exact and predicted solution at $t = 0.14, 0.69$ and 0.99 locations (bottom row) for the one-dimensional viscous Burgers equation. The vertical blue lines give the location of interface positions.

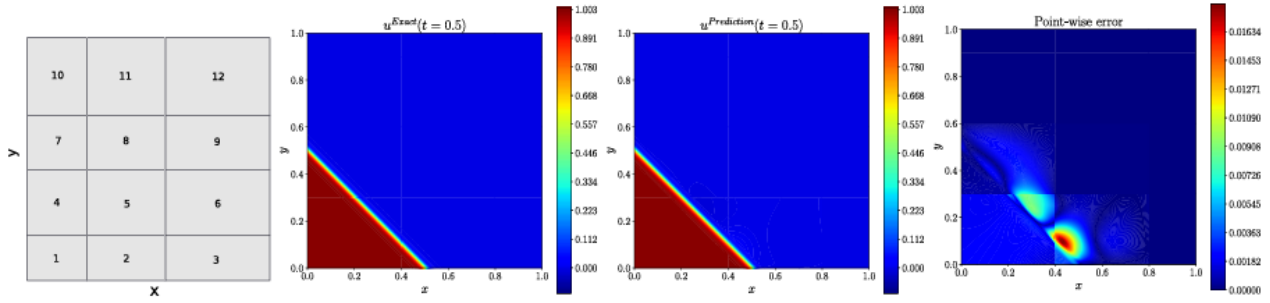


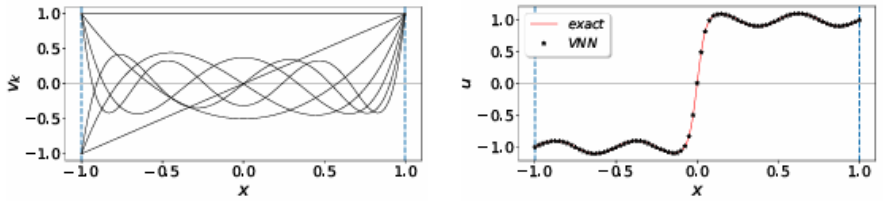
Fig. 9. (Left to right) 12 sub-domains numbering, exact solution, cPINN solution, and point-wise error of two-dimensional Burgers equation.

Jagtap (2020)

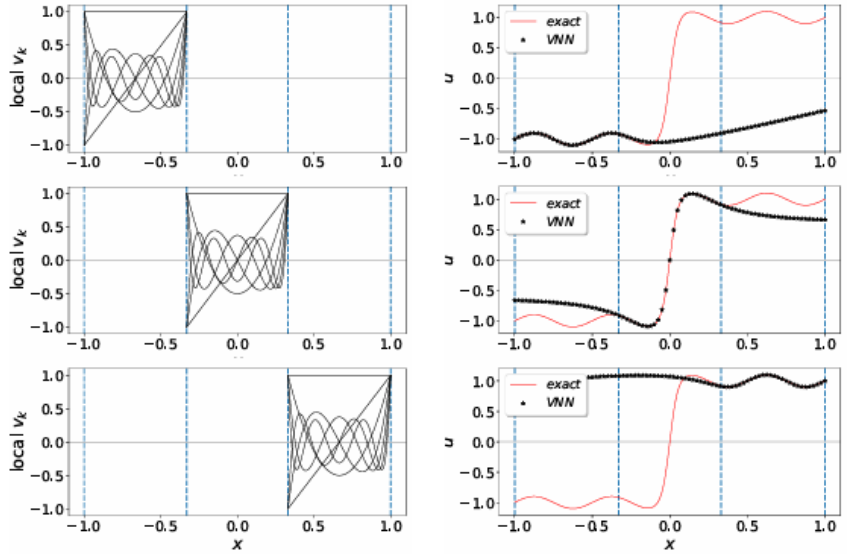
hp-VPINN: hp - Variational PINN

Esta estratégia **estende o VPINN** incorporando **decomposição de domínio (h-refinement)** e a capacidade de usar **polinômios de alta ordem localmente (p-refinement)** como funções de teste dentro de cada subdomínio.

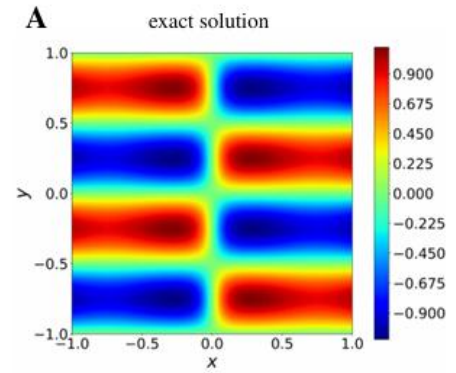
A principal diferença é a combinação da formulação **variacional com decomposição de domínio** e **funções de teste locais** baseadas em polinômios, permitindo adaptabilidade e refinamento local da solução de forma mais explícita e controlada do que no PINN global.

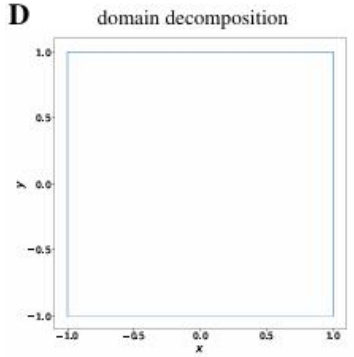


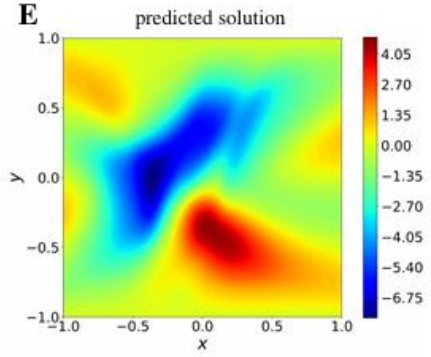
1 elemento



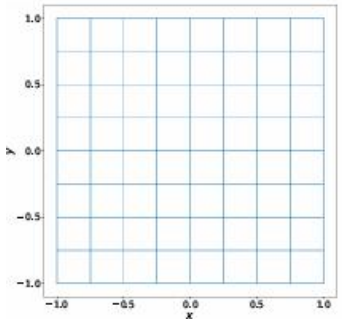
3 elementos

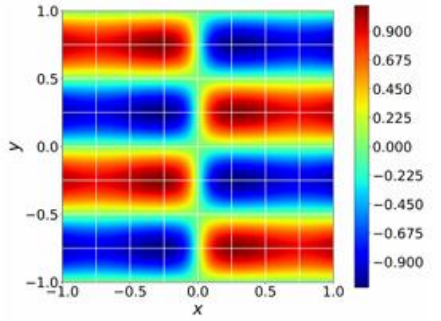






1 elemento





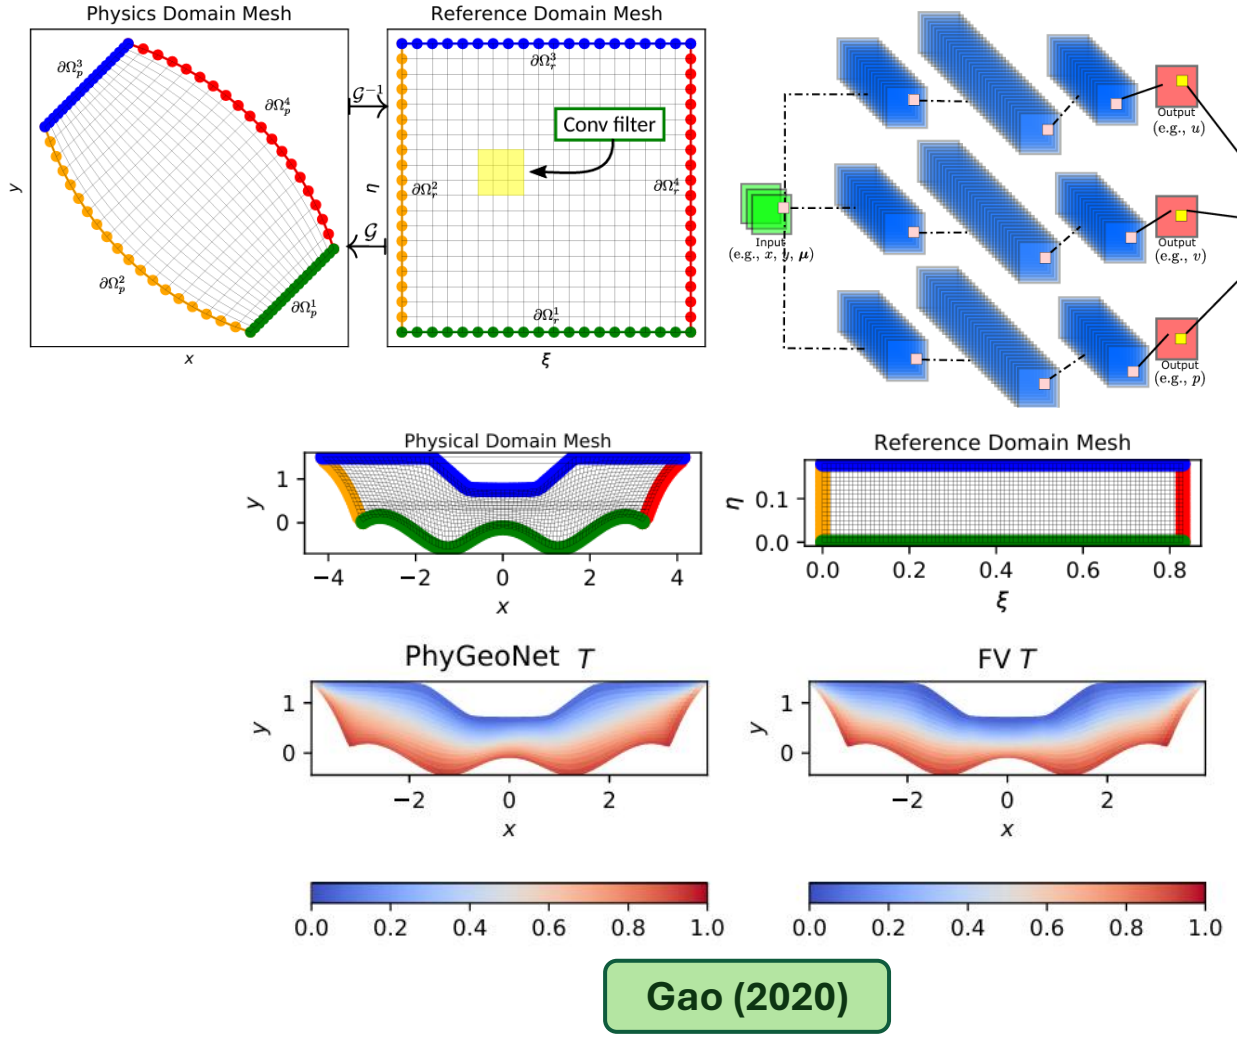
64 elementos

Kharazmi (2020)

PhyGeoNet: PI geometry-adaptive convolutional NNs

PhyGeoNet utiliza **redes neurais convolucionais (CNNs)** e é projetado para lidar com EDPs em domínios com **geometrias irregulares** e **malhas não uniformes**.

Ele emprega transformações de coordenadas, com **mapeamentos elípticos**, para levar a geometria complexa para um domínio de referência regular onde as **operações de convolução** padrão podem ser aplicadas.

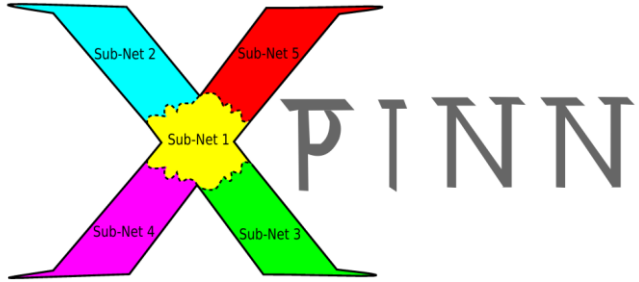


Gao (2020)

XPINN: eXtended PINN

XPINN é uma estrutura de **decomposição de domínio generalizada** que permite dividir o domínio computacional de **forma arbitrária no espaço e no tempo** para resolver qualquer tipo de EDP, **não se limitando a leis de conservação** como cPINN.

Ele usa redes neurais separadas em cada subdomínio e as conecta por meio de **condições de interface baseadas na continuidade residual** e/ou na solução média, facilitando a paralelização espaço-temporal.



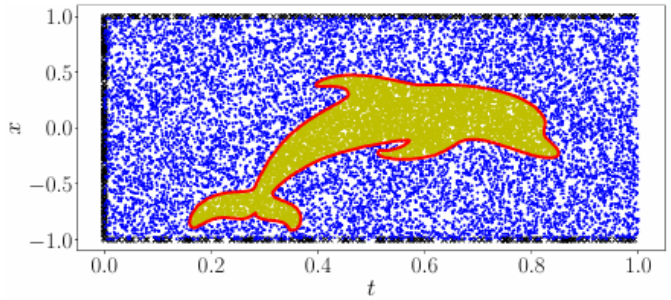
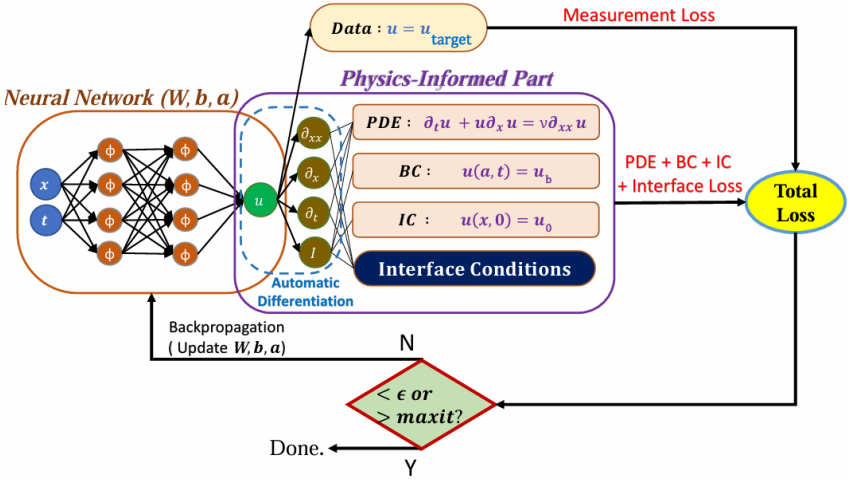
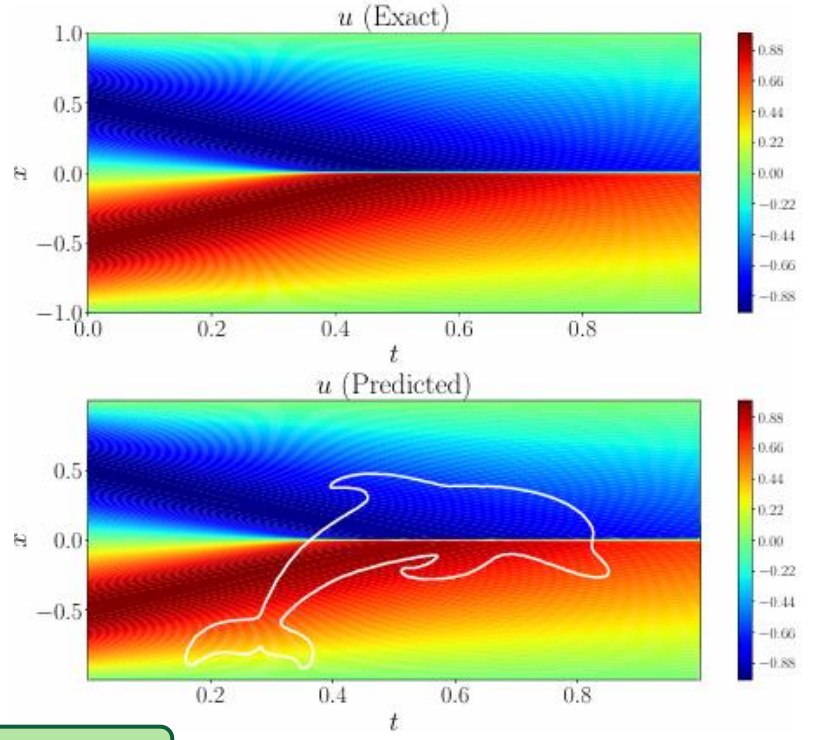


Figure 2: One-dimensional viscous Burgers equation: Residual points in subdomain 1 (blue stars) and subdomain 2 (yellow circles). Red line represent the dolphin shaped interface, which separates the two subdomains, and black cross represents the training data points from initial and boundary conditions.





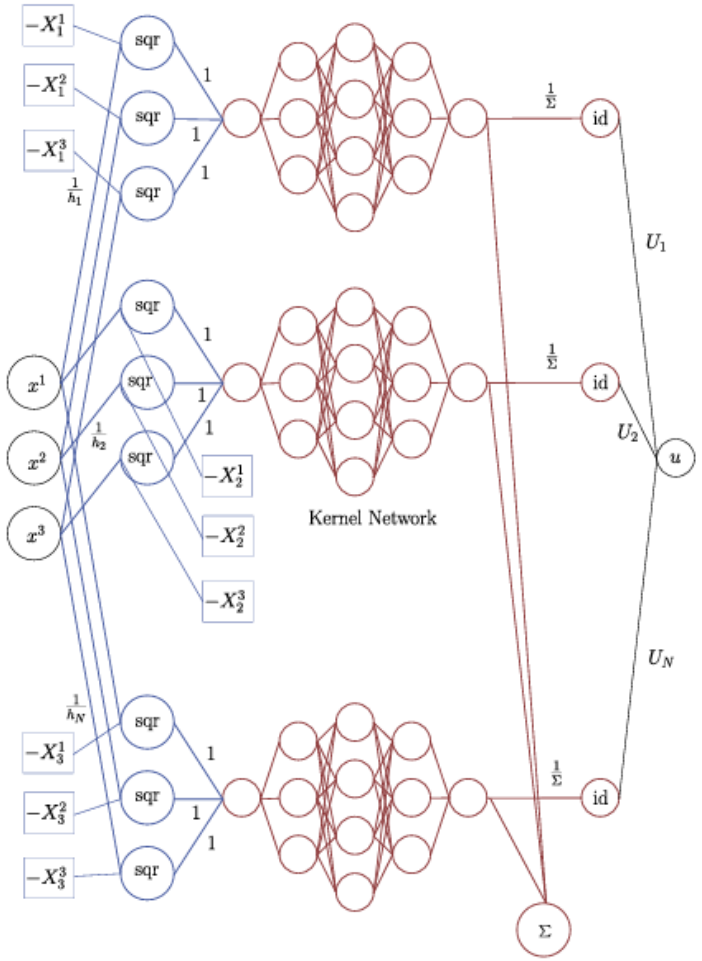
Jagtap (2021)

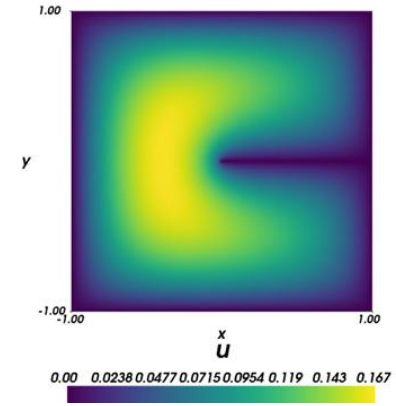
SPINN: Sparse, Physics-Based, and Partially Interpretable Neural Networks

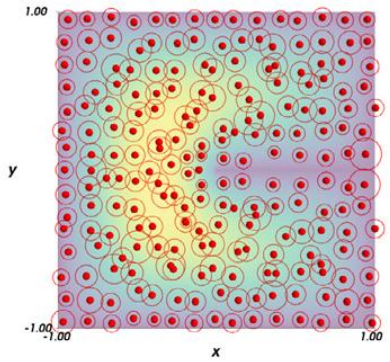
SPINN propõe uma nova classe de redes neurais esparsas que se inspiram em **métodos sem malha (meshless).**

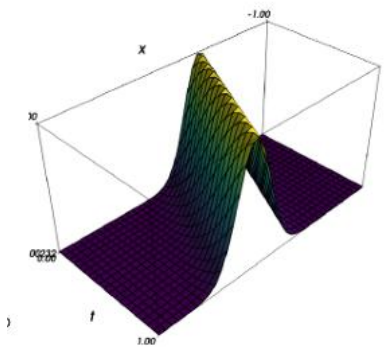
A arquitetura da rede é projetada para emular uma aproximação sem malha usando **funções base localizadas (kernels).**

Podem ser representadas por uma **pequena rede neural interna**, tornando a rede geral parcialmente interpretável e adaptável a descontinuidades e gradientes acentuados através da adaptação da posição e largura dos kernels.

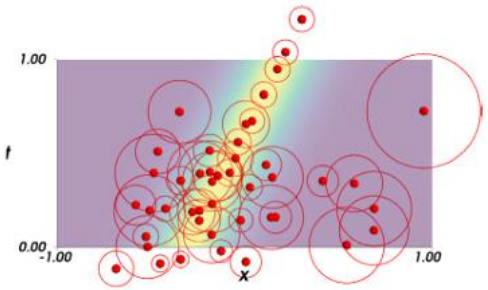








(b) Space-time solution



(c) Node and kernel width distributions

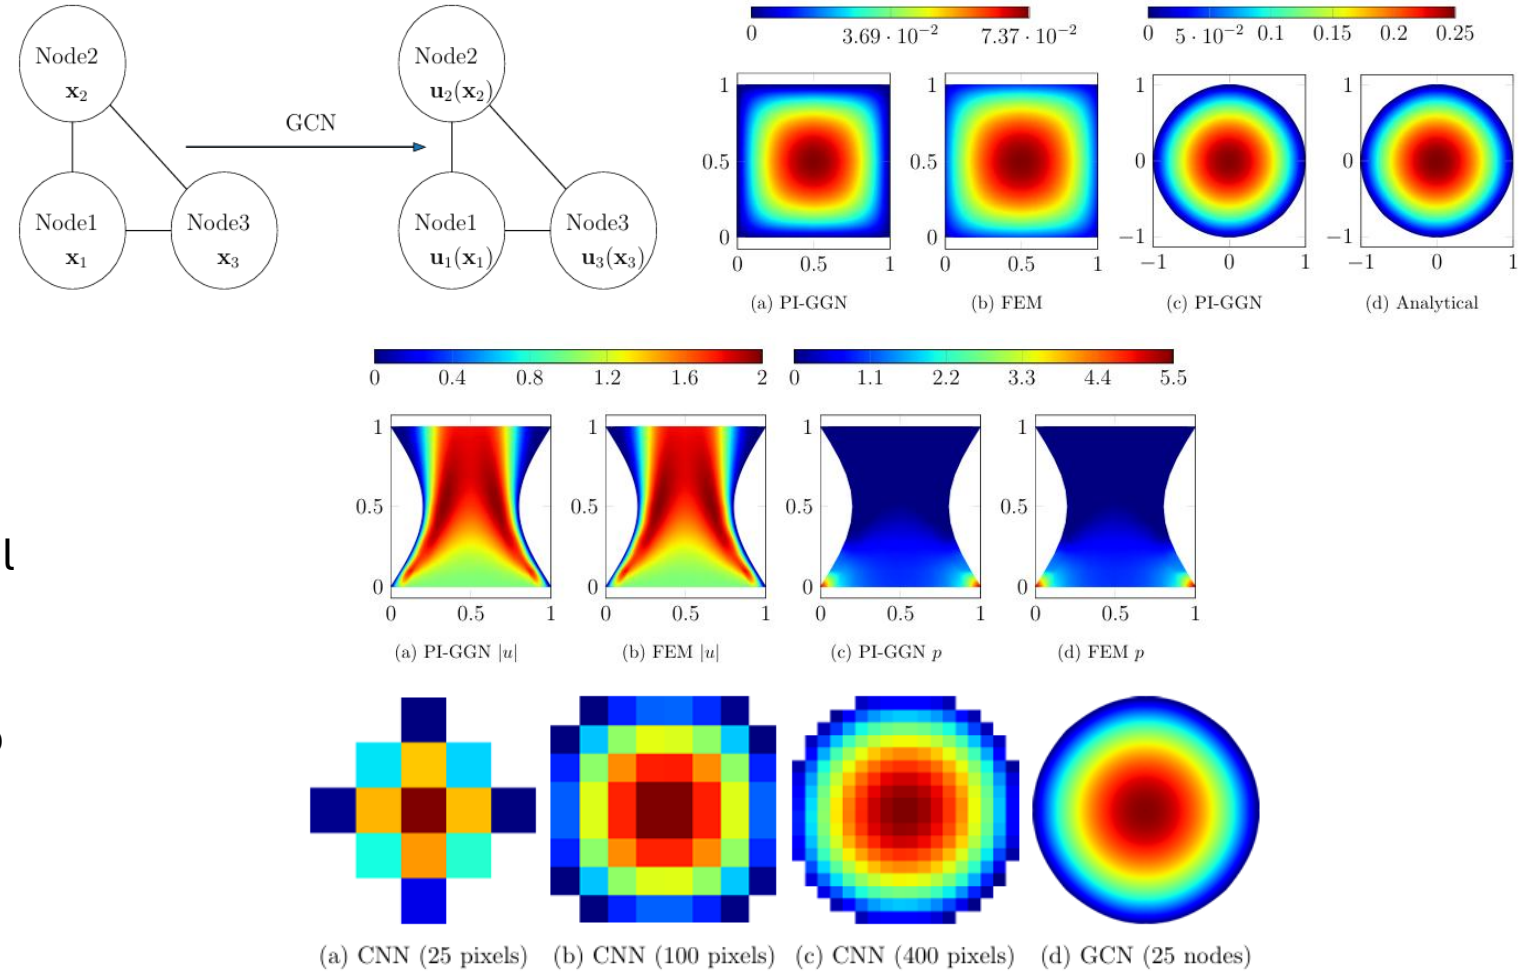
Ramabathiran (2021)

PIGCN: PI Graph Neural Galerkin Networks

Este framework discreto combina **redes neurais convolucionais de grafos (GCNs)** com a formulação **variacional de Galerkin** para resolver EDPs em malhas não estruturadas.

As GCNs operam **diretamente nos dados da malha** (representada como um grafo), e a função de perda é construída a partir da forma variacional da EDP.

Permitem a imposição rigorosa de condições de **contorno essenciais** e o tratamento de **geometrias complexas** de forma eficiente em malhas não estruturadas.



Gao etal (2022)

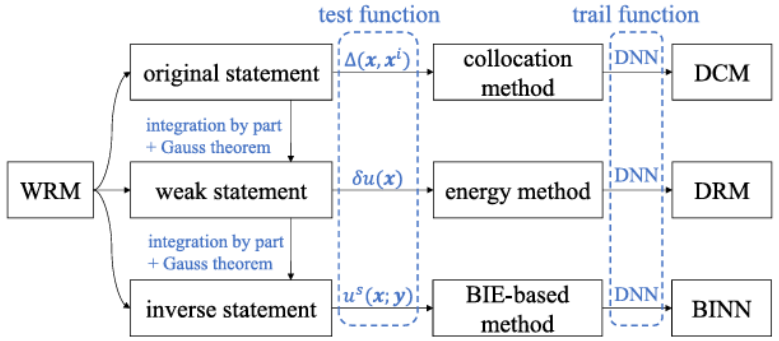
BINN: Boundary Integral type Neural Network

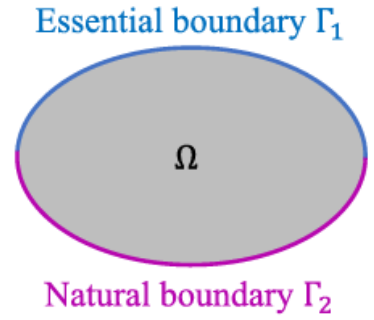
BINN reformula a solução de EDPs utilizando **equações integrais de contorno**.

Em vez de aproximar a solução no domínio inteiro, o BINN aproxima as incógnitas (campo e/ou suas derivadas) **apenas no contorno** utilizando uma rede neural.

A função de perda é então definida pelos **resíduos das equações integrais de contorno**, que naturalmente incorporam as condições de contorno e **reduzem a dimensão do problema**.

Sun etal (2023)

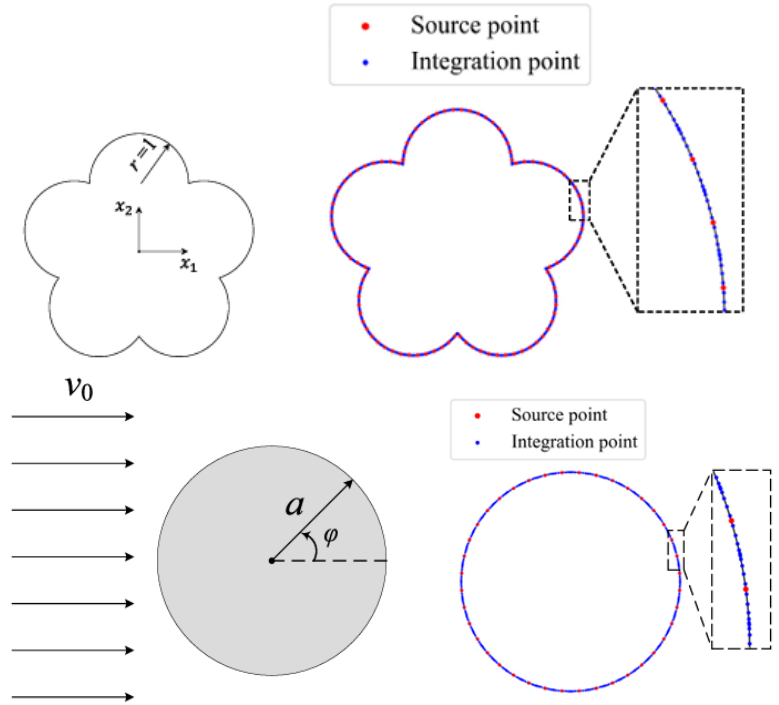




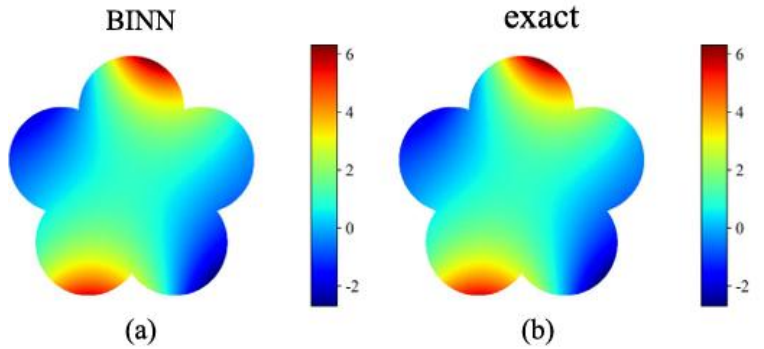
DCM loss = PDE loss on Ω
+ boundary loss on Γ_1
+ boundary loss on Γ_2

DRM loss = energy functional on Ω&Γ_2
+ boundary loss on Γ_1

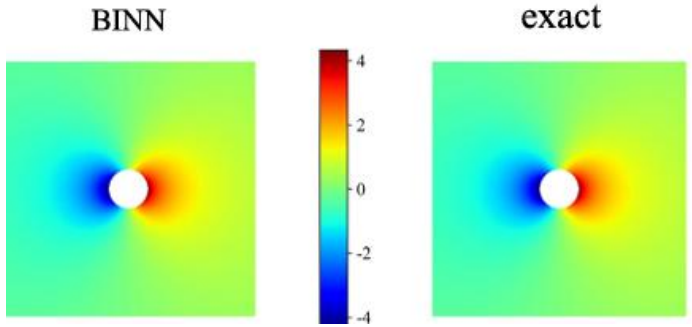
BINN loss = BIE loss on Γ_1 & Γ_2



Equação de Laplace 2D



Fluxo Potencial 2D

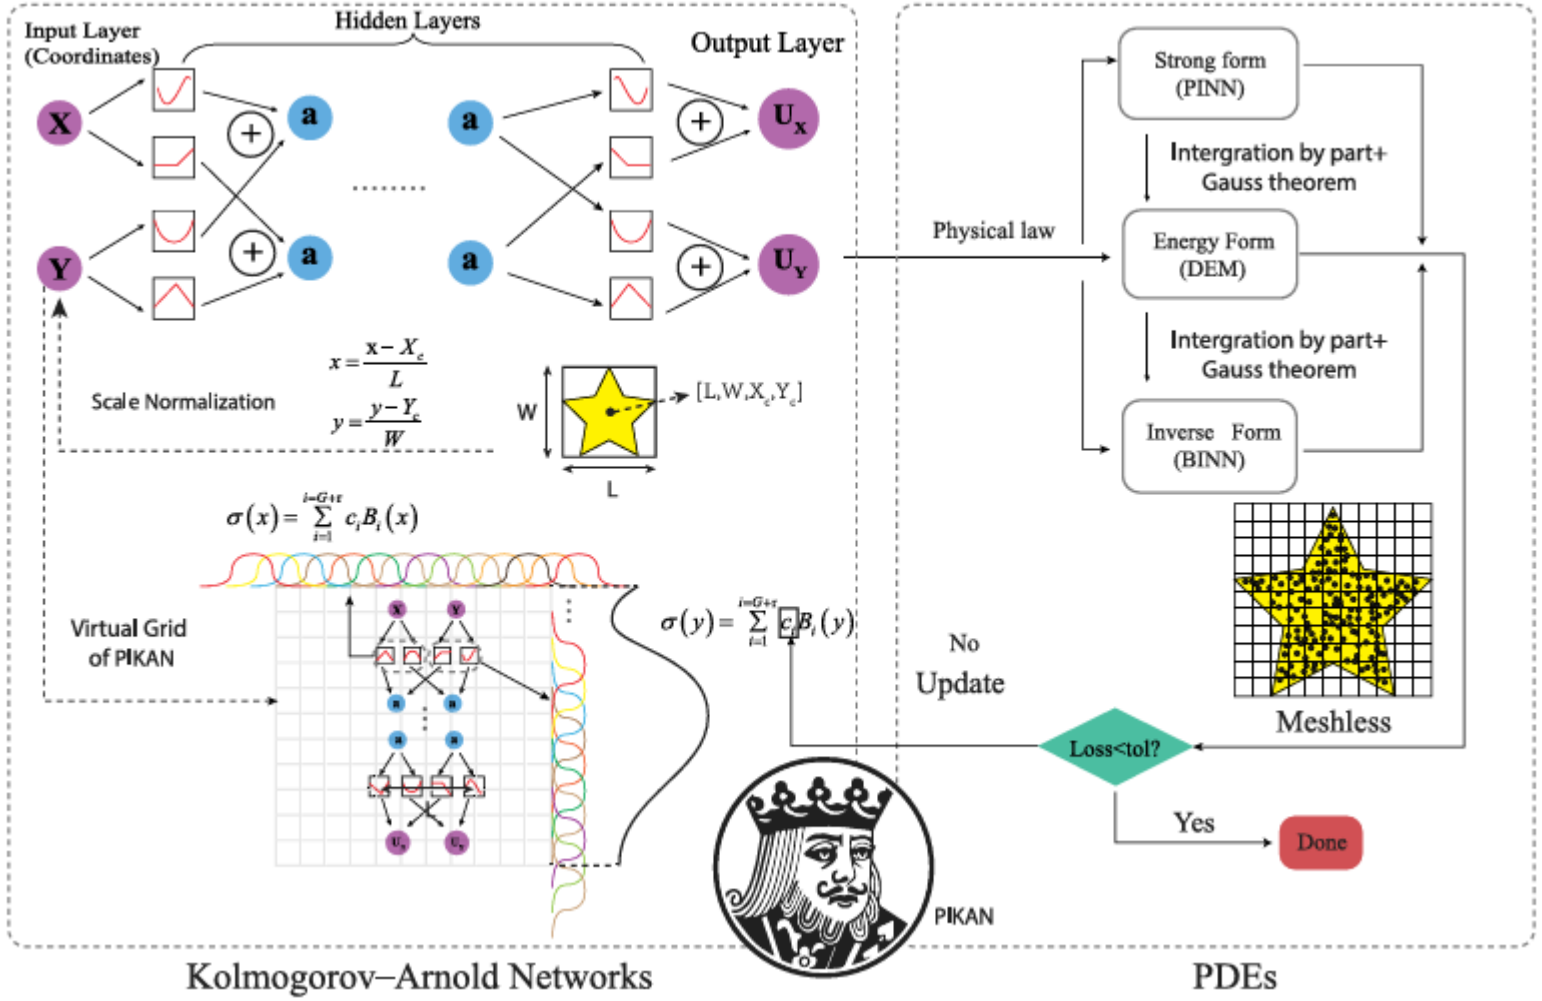


WRM: Weight Residual Methods | DCM: Deep Collocation Method | DRM: Deep Ritz Method | BIE: Boundary Integral Equations

KINN: Kolmogorov-Arnold-Informed Neural Networks

KINN ou PIKAN é uma abordagem que substitui a rede neural tradicional (MLP) tipicamente usada no framework PINN por **Kolmogorov-Arnold Networks (KANs).**

Essa substituição é aplicada a diferentes formulações de EDPs (**forte, energética, inversa**), buscando melhorar a **precisão**, a **interpretabilidade** e o tratamento de problemas com múltiplos scales ou descontinuidades devido às propriedades das KANs baseadas em **B-splines**.



Wang etal (2024b)



PINNs Energéticas

Deep Energy Methods (DEMs)

Afinal, o que são DEMs?

São PINNs em que a **função de perda** é baseada na **função potencial de energia do sistema**, sendo normalmente utilizada em problemas de Hiperelasticidade. No entanto pode ser usada em problemas de elasticidade linear, fratura etc. [Samaniego, 2019; Nguyen-Tahn, 2019; Kollmannsberger, 2021].

Método de Rayleigh-Ritz ou Imposição da aproximação na forma fraca*

Para exemplificar, tomamos como base da Mecânica dos Sólidos 2 ou Resistência dos Materiais princípios de energia como o PTV e o Teorema de Castigliano.

Podemos definir um funcional de energia:

$$\Pi = U_i - U_e$$

Em que U_i é a energia interna e U_e a energia externa, para um problema de elasticidade linear têm-se que:

$$U_i = \frac{1}{2}\int_{\Omega} \varepsilon : \mathbb{C} : \varepsilon \, d\mathrm{x} \Rightarrow \int_{\Omega} \frac{1}{2}\sigma^T \varepsilon \, d\mathrm{x}$$

*A forma fraca aqui está associada a diminuir o grau da derivada do problema, mas sem a ponderação como nos métodos variacionais/Galerkin.

Afinal, o que são DEMs?

Problema de uma barra

Vamos considerar que as propriedades e a área da seção não variam, então temos:

$$\frac{d}{dx}\left(\frac{du}{dx}\right) = -\frac{q(x)}{EA} = \mathrm{u}''$$

Problema de **tração**

$$u = \frac{PL}{EA} \Rightarrow du = \frac{Pdx}{EA} \Rightarrow \frac{P}{A} = E\frac{du}{dx} \Rightarrow \sigma = Eu' \qquad \varepsilon = u'$$

Substituindo na equação do slide anterior

$$U_i = \int_0^L \int_A (Eu'u')dAdx \rightarrow U_i = \frac{1}{2}\int_0^L EA(u')^2 dx$$

Para uma viga em flexão: a equação inicialmente tem uma derivada de quarta ordem que se reduz a

$$U_i = \frac{1}{2}\int_0^L EI(v'')^2 dx$$

Aqui as expressões das energias externas foram desconsideradas por praticidade, mas elas são necessárias para resolver os problemas num todo, ver Kollmannsberger (2021) Cap. 6.

Afinal, o que são DEMs?

Equações governantes de um problema de hiper-elasticidade

$$\text{Equilibrium:} \quad \nabla_X \cdot \boldsymbol{P} + \boldsymbol{f}_b = \boldsymbol{0},$$

$$\text{Dirichlet boundary} : \boldsymbol{u} = \overline{\boldsymbol{u}} \quad \text{on } \partial B_u,$$

$$\text{Neumann boundary} : \boldsymbol{P} \cdot \boldsymbol{N} = \overline{\boldsymbol{t}} \quad \text{on } \partial B_t,$$

$$\boldsymbol{F} = \nabla_X \boldsymbol{\varphi}(\boldsymbol{X}), \qquad \boldsymbol{P} = \frac{\partial \Psi}{\partial \boldsymbol{F}},$$

$$\textbf{Neo-Hookean:} \quad \Psi(I_1, J) = \frac{1}{2}\lambda\left[\log(J)\right]^2 - \mu \log(J) + \frac{1}{2}\mu\,(I_1 - 3),$$

$$\Pi(\boldsymbol{\varphi}) = \int_B \Psi \, dV - \int_B \boldsymbol{f}_b \cdot \boldsymbol{\varphi} \, dV - \int_{\partial B_t} \overline{\boldsymbol{t}} \cdot \boldsymbol{\varphi} \, dA.$$

$$\min_{\varphi \in H} \Pi(\boldsymbol{\varphi}),$$

Tipos de DEMs

Métodos	Tipo de Rede	Princípio Energético
Deep Ritz	Extreme Learning Machine	Variacional
DEM	Fully Connected	Mínimo Potencial de Energia
PFNN	Fully Connected	Variacional
mDEM	Fully Connected	Forma Mista
P-DEM	Fully Connected	Mínimo Potencial de Energia
CENN	Fully Connected	Mínimo Potencial de Energia
GCN-DEM	Graph Convolution (GCN)	Mínimo Potencial de Energia
PIRBN	Radial Basis Function	Mínimo Potencial de Energia
DCEM	Fully Connected	Mínimo Complementar de Energia
KINN	Kolmogorov Arnold Network	Mínimo Potencial de Energia

Adaptado de Wang etal (2024a)



Vídeos e Referências

Vídeos Recomendados

Vídeos

Physics Informed Neural Networks (PINNs): "PyTorch" Solve Physical Systems with Deep Neural Networks: https://youtu.be/MtHvs5FvtME?si=MeGVe9HF8pCkKN2j <Acesso em: 13/05/2025>

Physics Informed Neural Networks for Fluid Mechanics: https://youtu.be/EHrgSPHZG3Y?si=JUOWe1pC_7bt6i18 <Acesso em: 13/05/2025>

Playlists

Neural Networks / Deep Learning: https://youtube.com/playlist?list=PLblh5JKOoLUIxGDQs4LFFD--41Vzf-ME1 <Acesso em: 03/06/2025>

Physics Informed Machine Learning: https://youtube.com/playlist?list=PLMrJAkhIeNNQ0BaKuBKY43k4xMo6NSbBa <Acesso em: 06/06/2025>

Physics Informed Neural Networks (PINNs): https://youtube.com/playlist?list=PLM7DTyYjZGuLmg3f6j40fEF18jyQmYsC2 <Acesso em: 06/06/2025>

Referências

Dwivedi (2019) Physics Informed Extreme Learning Machine (PIELM)–A rapid method for the numerical solution of partial differential equations

Estevão etal (2023) Physics-informed Neural Networks For Solving Elasticity Problems

Gao etal (2020): PhyGeoNet: Physics-Informed Geometry-Adaptive Convolutional Neural Networks for Solving Parameterized Steady-State PDEs on Irregular Domain

Gao etal (2022): Physics-informed graph neural Galerkin networks: A unified framework for solving PDE-governed forward and inverse problems

Haghighat etal (2020): A physics-informed deep learning framework for inversion and surrogate modeling in solid mechanics

Hu etal (2024): Physics-informed Neural Networks (PINN) for computational solid mechanics: Numerical frameworks and applications

Jagtap (2020): Conservative physics-informed neural networks on discrete domains for conservation laws: Applications to forward and inverse problems

Referências

Jagtap (2021): Extended physics-informed neural networks (XPINNs): A generalized space-time domain decomposition based deep learning framework for nonlinear partial differential equations

Kharazmi (2019) VPINNs: Variational Physics-informed Neural Networks For Solving Partial Differential Equations

Kharazmi (2020) hp-VPINNs: Variational Physics-Informed Neural Networks With Domain Decomposition

Kollmannsberger etal (2021): Deep Learning in Computational Mechanics - An Introductory Course

Liu etal (2025) – KAN: Kolmogorov – Arnold Networks

Nentidis (2022) - Evaluation of Physics Informed Neural Networks in engineering simple structural analysis problems

Nguyen-Than (2019) - A deep energy method for finite deformation hyperelasticity

Referências

Raissi (2017) - Physics Informed Deep Learning (Part I): Data-driven Solutions of Nonlinear Partial Di erential Equations

Ramabathiran (2021)- SPINN: Sparse, Physics-based, and partially Interpretable Neural Networks for PDEs

Samaniego (2019) - An Energy Approach to the Solution of Partial Differential Equations in Computational Mechanics via Machine Learning: Concepts, Implementation and Applications

Vu-Quoc & Humer (2023): Deep Learning Applied to Computational Mechanics: A comprehensive Review, State of the Art, and the Classics

Wang etal (2024a)- Artificial intelligence for partial differential equations in computational mechanics: A review

Wang etal (2024b)- Kolmogorov-Arnold-Informed neural network: A physics-informed deep learning framework for solving forward and inverse problems based on Kolmogorov–Arnold Networks



Obrigado!